

Mercari 가격 제안 문제 선형회귀 모델링 보고서

LinearRegression · Ridge · Lasso 비교 및 RMSLE 기반 성능 분석

분석 대상 코드 : Mercari_Price_Suggestion_LinearRegression_pure.ipynb

분석 대상 데이터 : mercari_train.tsv (1,482,535행 × 8열)

작성일 : 2026-08-27

0. 개요

본 보고서는 Kaggle Mercari Price Suggestion Challenge 데이터를 대상으로, 상품의 이름·설명·브랜드·카테고리·상태·배송 정보로부터 판매 가격을 예측하는 선형 모델링 과정을 정리한다.

LinearRegression, Ridge, Lasso 세 모델을 동일한 피처 조합으로 비교했고, Ridge의 정규화 강도(alpha)는 수동 그리드 탐색과 Optuna 자동 탐색 두 방식으로 최적화했다.

최종적으로 Ridge(alpha=5)가 RMSLE 0.4792로 가장 낮은 오차를 기록했으며, 이는 실제 가격 대비 약 -38% ~ +61% 수준의 오차 범위에 해당한다. 세부 해석은 8장에서 다룬다.

1. 서론

1.1 연구 배경 및 필요성

Mercari는 판매자가 직접 상품 가격을 입력해야 하는 중고거래 플랫폼이다.

동일한 상품이라도 판매자마다 가격을 다르게 책정하면 거래 성사율과 플랫폼 신뢰도가 떨어진다. 상품 정보만으로 적정 가격대를 자동으로 제안할 수 있다면 판매자의 의사결정 부담을 줄일 수 있다.

1.2 과제 목적

- 상품명(name), 상품 설명(item_description), 브랜드, 카테고리, 상품 상태, 배송비 부담 여부로 가격을 예측한다.
- LinearRegression / Ridge / Lasso 세 가지 선형 회귀 모델의 성능을 RMSLE 기준으로 비교한다.
- Ridge의 alpha를 수동 그리드와 Optuna로 각각 탐색해 최적 정규화 강도를 찾는다.

2. 데이터셋 소개

2.1 데이터 개요

표 2-1. mercari_train.tsv 기본 정보

항목	내용
행 수	1,482,535
열 수	8
구분자	탭(\t)

표 2-2. 컬럼 구성

컬럼명	설명	결측치 수
train_id	고유 식별자	0
name	상품명	0
item_condition_id	상품 상태(1~5, 숫자가 클수록 상태가 나쁨)	0
category_name	카테고리 (대/중/소 계층, '/'로 구분)	6,327
brand_name	브랜드명	632,682
price	판매 가격 (목표 변수)	0
shipping	배송비 부담 여부(0/1)	0
item_description	상품 설명 텍스트	6

brand_name의 결측 비율은 약 42.7%로 가장 크다. 이는 4장의 브랜드 보완 작업의 근거가 된다.

3. 타깃 변수(Price) 분포 및 로그 변환

원본 price 분포는 저가 상품에 몰려 있고 고가 쪽으로 긴 꼬리를 가지는 형태다(오른쪽 꼬리 분포).

이런 비대칭 분포를 그대로 학습하면 소수의 고가 상품이 오차(손실)를 과도하게 지배해 모델이 저가 상품 예측에 소홀해질 수 있다.

이에 `np.log1p(price)` 로 로그 변환을 적용했다. 변환 후 분포는 좌우 대칭에 가까운 종 모양으로 바뀌었다(노트북 히스토그램 비교 셀 기준).

로그 변환의 두 번째 근거: 평가지표인 RMSLE 자체가 로그 오차 기반 지표다. 학습 목표를 로그 스케일로 맞추면 손실 함수와 평가지표의 방향이 일치해 최적화가 더 직접적으로 이뤄진다.

4. 피처 탐색 및 전처리

4.1 배송비·상품 상태 분포

표 4-1. shipping 값 분포

값	의미	건수	비율
0	구매자가 배송비 부담	819,435	55.3%
1	판매자가 배송비 부담	663,100	44.7%

표 4-2. item_condition_id 값 분포

값	건수	비율
1 (최상)	640,549	43.2%
2	375,479	25.3%
3	432,161	29.2%
4	31,962	2.2%
5 (최하)	2,384	0.2%

4.2 카테고리 계층 분할(대/중/소)

category_name을 '/' 기준으로 분리해 대분류(cat_dae), 중분류(cat_jung), 소분류(cat_so) 세 컬럼을 새로 만들었다. 결측인 경우 세 컬럼 모두 'Other_Null'로 채웠다.

표 4-3. 대분류(cat_dae) 분포

대분류	건수
Women	664,385
Beauty	207,828
Kids	171,689
Electronics	122,690
Men	93,680
Home	67,871
Vintage & Collectibles	46,530
Other	45,351
Handmade	30,842
Sports & Outdoors	25,342
Other_Null(결측)	6,327

중분류는 114종, 소분류는 871종이다. Women 카테고리가 전체의 약 45%를 차지해 카테고리 분포가 한쪽으로 크게 치우쳐 있다.

소분류(cat_so, 871종)는 최종 모델 피처에서 제외했다. 근거는 두 가지다.

- ① 대분류·중분류와 계층적으로 정보가 겹친다.
- ② 종류가 많아 각 범주별 표본 수가 적고, 선형모델의 회귀 계수 추정이 불안정해질 위험이 있다.

4.3 브랜드 결측치 보완

brand_name 결측 632,682건 중, 상품명(name)에 결측이 아닌 다른 행의 브랜드명이 그대로 포함된 경우를 찾아 역채움했다.

방식: 결측이 아닌 brand_name 값의 집합을 만든 뒤, 상품명 단어를 3단어·2단어·1단어 조합 순으로 확인해 이 집합에 속하는 조합이 있으면 그 값으로 채운다.

표 4-4. 브랜드 결측 보완 결과

구분	건수
보완 전 결측	632,682
상품명에서 역추론으로 채운 건수	148,714
역추론 후에도 남은 결측(Other_Null 처리)	483,968

이 방식은 새로운 브랜드 값을 만들지 않고 기존 브랜드 목록 안에서만 채우므로, 이후 브랜드 원-핫 인코딩의 차원 수에는 영향을 주지 않는다.

4.4 결측치 최종 처리

brand_name, category_name, item_description의 남은 결측치는 모두 'Other_Null' 문자열로 채웠다. 처리 후 전 컬럼의 결측치는 0건이다.

5. 피처 엔지니어링(벡터화)

5.1 텍스트 피처 벡터화

표 5-1. name / item_description 벡터화 설정

컬럼	방식	설정	결과 차원
name	CountVectorizer	min_df=2, max_features=20,000	1,482,535 × 20,000
item_description	TfidfVectorizer	max_features=20,000, ngram_range=(1,3), stop_words='english'	1,482,535 × 20,000

name은 평균 길이가 짧아 특정 단어가 한 상품명 안에서 반복되는 경우가 드물다. 따라서 단어 출현 빈도(TF) 방식인 CountVectorizer로 충분하다고 판단했다.

item_description은 문장이 길고, 여러 상품에서 공통으로 쓰이는 단어(설명 문구)가 많다. 이런 경우 TF-IDF로 특정 상품 설명에서만 두드러지는 단어에 가중치를 주는 것이 유리하다.

min_df=2는 1건에서만 등장하는 오탈자·희귀어를 걸러 노이즈를 줄이기 위한 설정이다. max_features=20,000은 차원을 벡터화 단계에서 직접 제한해 이후 SVD 등 추가 축소 없이

연산량을 통제하기 위한 설정이다.

5.2 범주형 피처 원-핫 인코딩

brand_name, item_condition_id, shipping, cat_dae, cat_jung 다섯 개 컬럼을 `LabelBinarizer(sparse_output=True)` 로 원-핫 인코딩했다.

희소 행렬(sparse matrix)로 인코딩한 이유는, brand_name처럼 범주 종류가 많은 컬럼을 밀집 배열(dense array)로 만들면 대부분이 0인 값에 메모리를 낭비하기 때문이다.

5.3 전체 피처 결합

위 벡터화·인코딩 결과를 `scipy.sparse.hstack` 으로 결합한 전체 피처 행렬의 크기는 아래와 같다.

표 5-2. 전체 피처 행렬 크기

행(샘플 수)	열(피처 수)
1,482,535	44,941

참고(산출값) : name(20,000) + item_description(20,000) + item_condition_id(5) + shipping(1, 이진 클래스라 LabelBinarizer가 1열 반환) + cat_dae(11) + cat_jung(114) = 40,131. 전체 44,941에서 이를 뺀 4,810이 brand_name 원-핫 차원(고유 브랜드 값 개수)으로 역산된다. 이 값은 노트북에 직접 출력되지 않아 다른 셀의 출력값으로부터 계산한 추정치임을 밝힌다.

6. 평가지표: RMSLE

RMSLE(Root Mean Squared Logarithmic Error)는 다음과 같이 정의한다.

$$\text{RMSLE} = \sqrt{\left(\frac{1}{n} \sum \left(\log(1+\hat{y}_i) - \log(1+y_i) \right)^2 \right)}$$

모델은 로그 변환된 price(3장)로 학습했으므로, 예측값과 실제값을 `np.exp`로 원래 가격 스케일로 복원한 뒤 RMSLE를 계산했다(`evaluate_org_price` 함수).

RMSLE는 절대 오차가 아닌 상대(비율) 오차 성격의 지표다. 즉 \$10짜리 상품의 \$5 오차와 \$100짜리 상품의 \$50 오차를 비슷한 비중으로 취급한다. 가격처럼 저가~고가 폭이 넓은 데이터에 적합한 이유다.

7. 모델링 및 결과

7.1 공통 학습·평가 방식

전체 피처 행렬을 `train_test_split(test_size=0.2, random_state=42)` 로 8:2 분할해 학습/평가했다. 교차검증(k-fold)은 적용하지 않은 단일 홀드아웃 검증이다.

7.2 LinearRegression: item_description 포함 여부

표 7-1. LinearRegression 결과

조건	RMSLE
item_description 포함(전체 피쳐)	0.4818
item_description 제외	0.5154

item_description을 포함하면 RMSLE가 0.5154 → 0.4818로 약 0.0335 감소한다. 상품 설명 텍스트가 가격 예측에 유의미한 정보를 담고 있음을 뜻한다.

7.3 Ridge(L2 정규화)

표 7-2. Ridge alpha별 RMSLE (전체 피쳐, solver='lsqr')

alpha	0.01	0.1	1	5	10
RMSLE	0.4812	0.4811	0.4800	0.4792	0.4798

alpha를 높이면 회귀 계수가 0 쪽으로 축소되어 분산은 줄지만 편향이 커진다(과소적합 방향). alpha를 낮추면 LinearRegression에 가까워져 분산이 커진다(과대적합 방향).

실험 범위 안에서는 alpha=5에서 RMSLE 0.4792로 가장 낮았고, alpha=10에서는 다시 소폭 상승했다. 즉 alpha 5 부근이 편향-분산 균형점에 가깝다.

7.4 Lasso(L1 정규화)

표 7-3. Lasso alpha별 RMSLE (전체 피쳐, max_iter=3000)

alpha	0.01	0.1	1	5	10
RMSLE	0.6924	0.7511	0.7511	0.7511	0.7511

Lasso는 모든 alpha에서 Ridge보다 크게 낮은 성능을 보였다. 특히 alpha=0.1 이상에서는 RMSLE가 완전히 동일한 값(0.7511)으로 고정된다.

alpha=0.1 이상에서 결과가 동일하다는 것은, 이 구간부터 대부분의 회귀 계수가 정확히 0으로 수렴해 모델이 사실상 절편(평균 예측) 수준으로 단순화되었을 가능성을 시사한다.

원인 추정: L1 정규화는 상관된 더미 변수(원-핫 인코딩된 브랜드·카테고리, TF-IDF 단어 조합)들 중 하나만 남기고 나머지를 0으로 만드는 경향이 Ridge(L2)보다 강하다. 44,941차원의 희소 피쳐 조합에서는 이 효과가 과도하게 작용해 정보 손실이 커진 것으로 판단된다.

7.5 Optuna 기반 Ridge alpha 탐색

수동 그리드 탐색에서 alpha=5 부근이 최적으로 나타나, 이 부근을 포함하도록 alpha 탐색 범위를 $1e-3 \sim 1e2$ (로그 스케일)로 설정하고 Optuna로 15회 시행했다.

표 7-4. Optuna 탐색 결과 요약

항목	값
시행 횟수	15
탐색 범위	$\alpha \in [0.001, 100]$, log-uniform
최적 α	2.3785
최적 RMSLE	0.47942

Optuna가 찾은 최적값($\alpha=2.3785$, RMSLE 0.47942)은 앞선 수동 그리드의 $\alpha=5$ 결과(RMSLE 0.47918)보다 근소하게 높다. 차이는 0.00024로 실질적으로 미미한 수준이다.

두 결과를 종합하면, α 1~10 구간에서 RMSLE 곡선이 상당히 평탄(flat)하며, 이 구간 어디를 택해도 성능 차이는 크지 않다고 해석할 수 있다.

7.6 전체 결과 비교

표 7-5. 전 모델 RMSLE 종합 비교

모델	조건	RMSLE
LinearRegression	item_description 포함	0.4818
LinearRegression	item_description 제외	0.5154
Ridge	$\alpha=0.01$	0.4812
Ridge	$\alpha=0.1$	0.4811
Ridge	$\alpha=1$	0.4800
Ridge	$\alpha=5$ (최적)	0.4792
Ridge	$\alpha=10$	0.4798
Ridge(Optuna)	$\alpha=2.3785$	0.4794
Lasso	$\alpha=0.01$	0.6924
Lasso	$\alpha \geq 0.1$	0.7511

7.7 Ridge 계수(coef_) 기반 피처별 영향 분석

7.3절에서 채택한 Ridge($\alpha=5$) 모델과 동일한 피처 조합·분할(`random_state=42`)로 다시 학습해 계수를 확보했다. 재학습 결과 RMSLE는 0.479180으로, 표 7-2의 원래 값(0.4792)과 사실상 동일하게 재현됐다.

학습된 계수(coef_)는 hstack 순서를 기준으로 name(20,000) · item_description(20,000) · brand_name(4,810) · item_condition_id(5) · shipping(1) · cat_dae(11) · cat_jung(114) 7개

블록으로 정확히 나뉜다. 44,941개 계수를 한 차트에 담는 것은 의미가 없으므로, 아래 6개 그룹으로 나눠 그룹별 상위·하위 계수만 시각화했다.

해석 시 유의할 점 세 가지.

- ① 계수는 다른 모든 피처가 0(해당 단어·범주가 없음)일 때를 기준으로 한 개별 효과다. 실제 상품은 여러 단어·범주가 동시에 있으므로 최종 예측가는 여러 계수의 합(+절편)으로 근사된다.
- ② 피처가 스케일링되지 않았다(원-핫은 0/1, TF-IDF는 대체로 0~1대 값). 따라서 **그룹 간** 계수 크기를 직접 비교하는 것은 부적절하며, **그룹 내** 상대 순위·차이 해석에 한정한다.
- ③ 타깃이 $\log_{1p}(\text{price})$ 이므로 계수는 로그 스케일 효과다. 같은 그룹 안에서 두 계수의 차를 $\exp()$ 로 변환하면 "다른 조건이 같을 때 대략 몇 배 차이인가"로 근사 해석할 수 있다(단, 이 역시 근사치다).

① name — 상품명 단어

상위권은 Owlet-DockATot(육아용품), Hatchimals(장난감), Dyson-Sonos-AirPods(가전/전자), Tieks(신발) 등 실제 프리미엄 브랜드·제품명이 다수 포함된다. 하위권은 dustbag-shoelaces-sticker-grips 등 저가 부속품·소모품 단어가 대부분이다. 예를 들어 "dyson"과 "dustbag" 두 단어의 계수 차는 2.069이며, $\exp(2.069) \approx 7.9$ 로, 다른 조건이 같다면 "dyson"이 들어간 상품명이 "dustbag"이 들어간 상품명보다 대략 7.9배 높은 가격대와 연관된 경향을 보인다. 다만 inr-9300hailey-007taz처럼 통상적 의미를 특정하기 어려운 토큰도 상위에 섞여 있는데, 이는 특정 판매자·상품군에 한정된 표본이 우연히 고가와 겹쳐 생긴 잡음(노이즈)일 가능성이 있어 일반화해 해석하지 않는다.




표 7-6. name 단어 상/하위 5개(전체 15개는 위 그림 참고)

상위(가격 ↑)		하위(가격 ↓)	
단어	계수	단어	계수
inr	1.627	dion	-1.067
owlet	1.585	colleggtibles	-0.905
dockatot	1.495	lightbar	-0.812
hatchimals	1.468	dustbag	-0.788
tyme	1.463	xls	-0.713

② item_description — 상품 설명 단어(n-gram)

상위권은 unlocked(잠금해제 휴대폰)·64gb/16gb/32gb(저장용량)·imei/tmobile/verizon(통신사 정보)·14k/carat(귀금속) 등 전자기기·주얼리 관련 표현이 뚜렷하게 몰려 있다. "unlocked"와 "envelope"(저가 소품 관련 문구)의 계수 차는 3.007, $\exp(3.007) \approx 20.2$ 로, 다른 조건이 같다면 "unlocked" 언급 상품이 "envelope" 언급 상품보다 대략 20배 높은 가격대와 연관된 경향을 보인다. 하위권에는 leave feedback·tracking처럼 판매자가 관용적으로 붙이는 문구도 섞여 있어, 이는 특정 단어 자체의 가치보다 해당 문구를 쓰는 판매자·상품군의 특성을 반영한 것일 수 있다.




표 7-7. item_description 단어(n-gram) 상/하위 5개

상위(가격 ↑)		하위(가격 ↓)	
단어	계수	단어	계수
unlocked	2.026	envelope	-0.981
limbs	1.869	jordan supreme	-0.937
carat	1.619	leave feedback	-0.810
14k	1.594	mobile phone	-0.798
64gb	1.524	tracking	-0.770

③ brand_name — 브랜드

상위권은 David Yurman·Tiffany & Co·Christian Louboutin·Saint Laurent·Balenciaga·Canada Goose 등 명품 주얼리·패션 브랜드, Vitamix·Blendtec 같은 프리미엄 주방가전 브랜드가 차지한다. 하위권은 eos·Post-it·Rimmel·Wet n Wild·Gold Bond 등 대중적인 저가 생활용품·드럭스토어 화장품 브랜드다. 최상위 David Yurman과 최하위 eos의 계수 차는 2.450, $\exp(2.450) \approx 11.6$ 으로, 다른 조건이 같다면 David Yurman 브랜드 상품이 eos 브랜드 상품보다 대략 11.6배 높은 가격대와 연관된 경향을 보인다. 브랜드 상/하위 순위가 실제 시장 인지도와 대체로 일치한다는 점은 모델이 그럴듯한 신호를 학습했다는 근거가 된다.





표 7-8. 브랜드 상/하위 5개

상위(가격 ↑)		하위(가격 ↓)	
브랜드	계수	브랜드	계수
David Yurman	1.855	eos	-0.594
Kendra Scott	1.233	Field & Stream	-0.583
Tiffany & Co.	1.128	Nicole Miller	-0.531
MICHELE	1.103	Geneva	-0.516
Spell & The Gypsy Collective	1.090	Gold Bond	-0.503


④ 카테고리 — 대분류(cat_dae) · 중분류(cat_jung)

대분류에서는 Electronics(+0.151)가 가장 높고 Beauty(-0.116)가 가장 낮다. 두 계수의 차는 0.266, $\exp(0.266) \approx 1.31$ 로 전자기기 대분류가 뷰티 대분류보다 대략 1.3배 높은 가격대와 연관된다. 중분류에서는 Musical instruments(+0.560)·Footwear(+0.413)· Strollers(+0.367) 등이 상위, Media(-0.461)·Magazines(-0.362)·Quilts(-0.317) 등이 하위다. 다만 중분류의 Cell Phones & Accessories(-0.223)와 Jewelry(-0.206)는 음수로, item_description에서 확인한 휴대폰·보석 관련 단어의 양의 효과와 방향이 반대로 보일 수 있다. 이는 모순이 아니라, 카테고리 계수가 텍스트 피쳐로 이미 설명된 부분을 제외한 잔차 효과이기 때문이다. 즉 실제 고가 상품의 가격 신호 대부분은 item_description의 구체적인 단어(unlocked, 64gb, carat 등)가 이미 흡수했고, 카테고리 자체에는 저가 액세서리 비중이 커서 잔차가 음수로 남은 것으로 해석된다.

대분류(cat_dae) 전체 가격 영향



중분류(cat_jung) 상/하위 15개






표 7-9. 대분류(cat_dae) 전체 11개

대분류	계수	대분류	계수
Electronics	0.151	Sports & Outdoors	-0.002
Men	0.096	Women	-0.007
Vintage & Collectibles	0.048	Handmade	-0.032
Kids	0.007	Other	-0.047
Other_Null	0.0001	Home	-0.098
		Beauty	-0.116

⑤ item_condition_id · ⑥ shipping

item_condition_id는 1(최상)에서 5(최하)로 갈수록 계수가 $+0.226 \rightarrow +0.141 \rightarrow +0.068 \rightarrow -0.155 \rightarrow -0.280$ 으로 단조 감소한다. "상품 상태가 좋을수록 비싸다"는 상식과 정확히 일치하는, 모델이 학습한 가장 깔끔한 관계다. 1과 5의 계수 차는 0.506, $\exp(0.506) \approx 1.66$ 으로, 다른 조건이 같다면 최상 상태 상품이 최하 상태 상품보다 대략 1.66배 높은 가격대와 연관된다.

shipping은 이진 변수라 계수가 하나뿐이다. lb_shipping.classes_는 [0, 1]이며 변환 결과 값 자체가 그대로 컬럼값이 되므로, 이 계수는 "판매자가 배송비를 부담하는 경우(shipping=1)"의 효과다. 계수는 -0.194, $\exp(-0.194) \approx 0.82$ 로, 다른 조건이 같다면 판매자가 배송비를 부담하는 상품이 그렇지 않은 상품보다 대략 18% 낮은 가격대와 연관되는 경향을 보인다. 이는 저가 상품일수록 판매자가 무료배송으로 구매를 유도하는 경우가 많다는 일반적인 온라인 중고거래 패턴과 방향이 일치한다.




표 7-10. item_condition_id 전체 5개 및 shipping

item_condition_id	계수
1(최상)	0.226
2	0.141
3	0.068
4	-0.155
5(최하)	-0.280
shipping(=1, 판매자 부담)	-0.194

종합하면, 모델이 학습한 방향성은 실제 시장 상식과 대체로 일치한다: 전자기기·주얼리·명품 브랜드·상품 상태가 좋을수록, 그리고 판매자가 배송비를 부담하지 않을수록 가격이 높게 예측된다. 이는 9장 종합평가에서 다루는 RMSLE 수치만으로는 보이지 않는, 모델이 "그럴듯한 이유로" 가격을 예측하고 있다는 정성적 근거가 된다.

8. 결과 해석: RMSLE의 실제 가격 의미

RMSLE는 로그 오차 지표라, 예측 가격이 실제 가격 대비 대략 어느 비율 범위에 있는지로 환산해 해석할 수 있다.

근사식: 예측 가격 $\approx$ 실제 가격 $\times e^{(\pm \text{RMSLE})}$

표 8-1. 모델별 RMSLE를 가격 범위로 환산 (근사치)

모델(조건)	RMSLE	실제가 \$10일 때	실제가 \$50일 때	실제가 \$100일 때
Ridge alpha=5 (최적)	0.4792	\$6.19 ~ \$16.15	\$30.97 ~ \$80.74	\$61.93 ~ \$161.48
LinearRegression(설명 포함)	0.4818	\$6.18 ~ \$16.19	\$30.89 ~ \$80.95	\$61.77 ~ \$161.90
LinearRegression(설명 제외)	0.5154	\$5.97 ~ \$16.74	\$29.87 ~ \$83.71	\$59.73 ~ \$167.42
Lasso(alpha≥0.1, 사실상 절편모델)	0.7511	\$4.72 ~ \$21.19	\$23.59 ~ \$105.97	\$47.18 ~ \$211.93

주의: 위 범위는 RMSLE를 로그오차의 대표적 크기로 보고 역산한 근사치이며, 실제 개별 예측이 이 구간 안에 들어간다는 통계적 보장은 아니다. RMSLE는 오차 제곱의 평균을 다시 제곱근한 값이라 일부 극단적으로 빗나간 예측(긴 꼬리)의 영향을 받으며, 실제 오차 분포는 이 근사 구간보다 더 넓게 퍼져 있을 수 있다.

그럼에도 모델 간 상대 비교는 유효하다. 최적 Ridge는 Lasso(절편모델 수준) 대비 오차 범위 폭이 뚜렷하게 좁다. 예를 들어 \$50 상품 기준 Ridge는 약 \$50 폭(≈\$31~\$81)인 반면 Lasso는 약 \$82 폭(≈\$24~\$106)으로 두 배 이상 넓다.

9. 종합 평가

- 텍스트 피쳐, 특히 item_description은 가격 예측력에 실질적으로 기여한다(7.2절).
- 세 모델 중에서는 Ridge가 가장 낮은 RMSLE를 기록해 가장 안정적이었다.
- Lasso는 고차원 희소 피쳐(44,941차원) 환경에서 계수를 과도하게 0으로 축소해, 이번 데이터·피쳐 조합에는 적합하지 않았다.
- Optuna 자동 탐색은 수동 그리드 탐색과 유사한 최적 지점(alpha 2~5 구간)을 확인해, 최적점의 위치가 신뢰할 만함을 뒷받침한다.
- Ridge 계수를 그룹별로 뜯어보면 전자기기·주얼리·명품 브랜드·상품 상태(1등급)일수록 가격이 높게, 판매자 부담 배송일수록 낮게 예측되는 등(7.7절) 방향성이 실제 시장 상식과 대체로 일치한다.

10. 결론

본 분석에서 최종적으로 채택할 모델은 **Ridge(alpha=5)**이며, RMSLE 0.4792를 기록했다.

이는 실제 가격 대비 대략 -38% ~ +61% 오차 범위(8장 근사 해석 기준)에 해당한다. 절대적인 정확도로 보면 여전히 오차 폭이 크므로, 실무에 바로 적용하기보다는 가격 "구간 제안"의 참고 지표로 활용하는 편이 적절하다.

11. 한계 및 향후 과제

- **검증 방식:** 단일 홀드아웃(8:2) 검증만 수행했다. k-fold 교차검증을 적용하면 RMSLE 추정치의 변동성을 함께 확인할 수 있다.
- **미사용 피처:** 소분류(cat_so, 871종)는 카디널리티 문제로 제외했다. 임베딩 또는 빈도 기반 인코딩 등 다른 처리 방식을 시도해볼 여지가 있다.
- **테스트 제출 미실시:** 본 노트북은 mercari_train.tsv 내부 홀드아웃 평가까지만 수행했고, Kaggle 실제 테스트셋 제출 결과는 포함하지 않는다.
- **모델 계열의 한계:** 선형모델은 피처 간 비선형 상호작용을 반영하지 못한다. 트리 기반 모델 (LightGBM 등)과의 비교는 이번 분석 범위에 포함되지 않았으며, 후속 과제로 제안한다.
- **Lasso 결과의 추가 검증:** $\alpha \geq 0.1$ 구간에서 계수가 실제로 0에 수렴했는지는 계수 배열을 직접 확인하지 않아 정황적 추정이다. 후속 분석에서 `model.coef_`의 0 비율을 직접 확인하면 더 확실하다.

12. 참고 자료

- 분석 노트북: Mercari_Price_Suggestion_LinearRegression_pure.ipynb
- 데이터: mercari_train.tsv (Kaggle Mercari Price Suggestion Challenge)

부록. 노트북 내 정의 함수

표 A-1. 노트북에서 정의한 주요 함수

함수명	역할
split_cat	category_name을 '/' 기준 대/중/소분류로 분리. 결측 시 'Other_Null' 3개 반환
find_brand_in_name	상품명 단어 조합(3→2→1단어)을 기존 브랜드 목록과 대조해 브랜드명 역추론
rmsle	실제값·예측값(원가격 스케일)으로 RMSLE 계산
evaluate_org_price	로그 스케일 예측값·실제값을 expm1로 복원한 뒤 rmsle 호출
model_train_predict	피처 리스트 결합(hstack) → 8:2 분할 → 학습 → 예측까지 수행하는 공통 파이프라인