

머신 러닝 기반 데이터 분석

세미 프로젝트

이민석

요지

1. 과제 개요 및 목적

1.1. 추진 배경 및 필요성

현대 산업 전반에서 데이터 기반의 합리적 의사결정 역량은 기업의 핵심 경쟁력으로 자리 잡고 있다.

이에 따라 본 과제는 이론적 지식에 머무르지 않고, 실제 대규모·고차원 공개 데이터셋을 대상으로 탐색적 데이터 분석(EDA)부터 최종 모델 최적화에 이르는 머신러닝 파이프라인의 전 과정(End-to-End Analytics Lifecycle)을 직접 설계하고 완주하는 것을 궁극적인 목적으로 한다.

실무 환경에서 마주할 수 있는 복잡한 데이터 특성을 스스로 진단하고 해결하는 능력을 배양하고자 한다.

1.2. 핵심 수행 단계 및 방법론

본 과제는 성공적인 데이터 분석 및 예측 모델 구축을 위해 다음의 네 가지 체계적인 단계를 거쳐 수행된다.

고차원·대규모 데이터 탐색적 분석 (Exploratory Data Analysis)
수백 개 이상의 변수와 방대한 샘플 규모로 이루어진 복잡한 데이터를 통계적 관점에서 깊이 있게 이해한다.

다양한 시각화 기법을 동원하여 데이터 내재된 구조, 변수 간 상관관계, 그리고 잠재적 패턴을 다각도로 파악함으로써 후속 전처리의 방향성을 설정한다.

데이터 고도화 및 품질 관리 (Preprocessing & Imbalance Correction)

데이터의 신뢰성을 저해하는 결측치와 이상치를 엄밀하게 식별하여 적절한 방법론으로 정제한다.

비즈니스 인사이트를 반영한 파생 변수를 생성하여 모델의 설명력을 높이고, 실무 데이터에서 빈번히 발생하는 클래스 불균형 문제를 해소하기 위해 SMOTE(Synthetic Minority Over-sampling Technique) 등의 오버샘플링 기법을 적용하여 학습 데이터의 편향을 보정한다.

다각적 모델링 및 성능 검증 (Modeling & Comparative Evaluation)

풀고자 하는 문제의 유형(예: 회귀, 분류 등)에 부합하는 다수의 머신러닝 알고리즘을 선정하고 병렬적으로 학습을 수행한다.

1.3 기대 효과

단순 정확도를 넘어선 객관적이고 신뢰도 높은 평가 지표를 활용하여 모델별 성능을 정밀하게 비교·검증함으로써 최적의 베이스라인 모델을 도출한다.

하이퍼파라미터 자동화 최적화 (Hyperparameter Optimization) 수동

탐색(Grid/Random Search)의 한계를 극복하고 최적의 조합을 효율적으로 탐색하기 위해 Hyperopt 등의 베이지안 기반 하이퍼파라미터 자동화 최적화 기법을 도입한다.

이를 통해 모델의 예측 성능을 이론적 한계치까지 극대화하고, 안정적이고

강건한(Robust) 최종 예측 시스템을 완성한다.

결론적으로 본 과제는 체계적인 데이터 공학과 머신러닝 최적화 프로세스의 결합을 통해, 실무 현장에서 직면하는 비정형·고차원 데이터 문제를 창의적이고 효과적으로 해결할 수 있는 데이터 사이언티스트로서의 역량을 확립하는 데 그 의의가 있다.

목 차

요 지	
목 차	
그림목차	
표 목 차	
1. 서 론	
1.1 데이터 분석 프로젝트 추진 배경 및 목적	
1.2 전체 보고서 구성 및 방법론 개요	
2. 캐글 산탄데르 데이터 앙상블 분류 분석	
2.1 산탄데르 데이터셋 개요 및 탐색적 분석(EDA)	
2.2 고차원 수치형 데이터 전처리 및 특성 공학	
2.3 앙상블 기법을 활용한 고객 거래 분류 예측	
2.4 모델 성능 평가 및 최적화 결과 분석	
3. 캐글 신용카드 사기 검출	
3.1 신용카드 사기 데이터 특성 및 클래스 불균형 문제 진단	
3.2 통계적 추론 및 변수 간 다중공선성 진단	
3.3 불균형 데이터 보정(SMOTE 적용) 및 전처리	
3.4 베이스라인 모델 평가	
3.5 로지스틱 회귀 통계적 해석 및 오즈비 분석	
3.6 앙상블 분류 모델 학습 및 성능비교	
3.7 모델 해석(Feature Importance & SHAP)	

3.8	종합비교 및 최종 결론
4.	Opinions 리뷰 데이터를 이용한 군집 분석.....
4.1	분석 개요
4.2	군집 수 결정 및 주제 라벨링
4.3	군집-감성 관계 분석
4.4	통계적 검증.....
4.5	군집 해석 시 주의사항
4.6	종합 시각화 및 해석
5.	Mercari 상품 가격 분석 및 예측
5.1	문제 정의
5.2	데이터 이해 및 탐색적 데이터 분석
5.3	데이터 전처리 및 텍스트 정제
5.4	머신러닝 모델링 및 성능 비교.....
5.5	결론 및 향후 개선 방안
6.	결론.....
6.1	4가지 핵심 과제별 주요 분석 결과 요약
6.2	종합 시사점 및 향후 제언

그림 목차

그림 2-1. 고객 만족도(TARGET) 클래스 불균형 분포.....	
그림 2-2. 고객 나이(var15) 구간별 불만족 비율.....	
그림 2-3. 최근 3개월 계좌 활동 월 수 구간별 불만족 비율.....	
그림 2-4. 추정 계좌 잔고 구간별 불만족 비율.....	
그림 2-5. 계좌 잔고(saldo_var30) 만족·불만족 그룹 Boxplot 비교	
그림 2-6. 고객 나이(var15) 만족·불만족 그룹 Boxplot 비교	
그림 2-7. 주요 변수 간 상관관계 히트맵	
그림 2-8. 만족·불만족 그룹별 주요 변수 평균 비교.....	
그림 2-9. 통계적 검정 기반 변수 유의성 결과 상위 5개(p-value, effect size).....	
그림 2-10. 상관관계 기반 중복 변수 그룹화 결과	
그림 2-11. LASSO 변수 선택 결과(절대 계수 상위).....	
그림 2-12. Random Forest 변수 중요도(Feature Importance)	
그림 2-13. XGBoost 변수 중요도(Feature Importance)	
그림 2-14. XGBoost Threshold별 Precision·Recall·F1 결과	
그림 2-15. SHAP Summary Plot (XGBoost 변수별 예측 기여도).....	
그림 3-1. 클래스 불균형·거래 금액 분포·거래 시간 분포.....	
그림 3-2. Amount·Class·V1~V14 변수 간 상관관계 히트맵	
그림 3-3. Mann-Whitney U 검정 및 Cohen's d 효과크기 상위 10개 변수	
그림 3-4. 변수별 효과크기(Cohen's d) 상위 10개.....	
그림 3-5. 변수별 VIF(분산팽창요인) 상위 10개.....	
그림 3-6. Train/Test 분할 결과 및 사기 비율 검증.....	
그림 3-7. 베이스라인 모델 평가 결과(ROC-AUC·PR-AUC·Classification Report)	
그림 3-8. 베이스라인 모델 혼동행렬(Confusion Matrix).....	
그림 3-9. 로지스틱 회귀계수 및 오즈비(Odds Ratio) 산출 결과	
그림 3-10. 오즈비 포레스트 플롯(Forest Plot)	
그림 3-11. 앙상블 모델별 주요 하이퍼파라미터 구성	
그림 3-12. 5개 모델 × 3가지 불균형 처리 기법 종합 성능 비교	
그림 3-13. SHAP Feature Importance (최적화 XGBoost).....	
그림 3-14. SHAP Beeswarm Plot (최적화 XGBoost)	
그림 3-15. Threshold 최적화 결과	
그림 3-16. 최종 5개 모델 종합 성능 비교 결과	
그림 4-1. 엘보우 방법 - 클러스터 수(K)별 Inertia	

그림 4-2. 군집별 평균 감성 점수.....	
그림 4-3. 제품 × 군집 평균 감성 히트맵	
그림 4-4. 군집별 감성 영향력 (Ridge 회귀계수)	
그림 4-5. 군집별 체르노프 페이스	
그림 5-1. Mercari 상품 가격(원본, price) 분포	
그림 5-2. 로그 변환 가격(log1p(price)) 분포.....	
그림 5-3. IQR 기준(57.5 초과) 고가 상품 분포	
그림 5-4. 상품 상태(item_condition_id)별 분포.....	
그림 5-5. 배송비 부담 주체(shipping)별 분포.....	
그림 5-6. 상위 20개 카테고리별 상품 분포	
그림 5-7. 상위 20개 브랜드별 상품 분포	
그림 5-8. 상품 상태별 가격 중앙값	
그림 5-9. 배송비 부담 주체별 가격 중앙값	
그림 5-10. 배송비 부담 주체별 로그 가격 분포(Boxplot)	
그림 5-11. 상위 20개 카테고리별 가격 중앙값	
그림 5-12. 상위 20개 카테고리별 로그 가격 분포(Boxplot)	
그림 5-13. 상위 20개 브랜드별 가격 중앙값	
그림 5-14. 상위 20개 브랜드별 로그 가격 분포(Boxplot)	
그림 5-15. 잔차 대 예측값(Fitted Values) 산점도	
그림 5-16. 회귀모형 잔차 분포.....	
그림 5-17. 머신러닝 모델별 RMSLE 종합 비교	

표 목차

표 4-1. 군집별 OLS 회귀계수 및 유의성 검정 결과 (1차, VIF 정제 전)	
표 4-2. 군집별 OLS 회귀계수 및 유의성 검정 결과 (VIF 정제 후)	
표 4-3. 다중공선성(VIF) 상위 15개 변수 (1차)	
표 4-4. 다중공선성(VIF) 상위 15개 변수 (정제 후)	
표 5-1. 다중공선성(VIF) 상위 8개 변수 (1차, VIF>10 기준 제거 대상)	
표 5-2. OLS 모델 단계별 비교 (Full → VIF 정제 → 최종 297개 변수)	
표 5-3. 최종 OLS 모델의 회귀분석 가정 검토 결과	
표 5-4. 머신러닝 모델별 예측 성능(RMSLE) 종합 비교	
표 6-1. 4가지 핵심 과제 분석 결과 종합 비교	

1. 서론

1.1 데이터 분석 프로젝트 추진 배경 및 목적

1) 추진 배경 및 필요성

현대 산업 및 비즈니스 환경 전반에서 데이터 기반의 합리적 의사결정 역량은 조직의 핵심 경쟁력으로 자리 잡고 있다. 이에 따라 본 프로젝트는 이론적 지식의 습득을 넘어, 실제 공개된 대규모·고차원 데이터셋을 대상으로 탐색적 데이터 분석(EDA)부터 최종 모델 최적화에 이르기까지 머신러닝 파이프라인의 전 과정(End-to-End Analytics Lifecycle)을 직접 설계하고 완주하는 것을 목적으로 한다.

실무 현장에서 직면하는 데이터는 결측치, 클래스 불균형, 고차원 희소성(Sparsity) 등 다양한 문제를 내포하고 있다. 따라서 이러한 복잡한 데이터 특성을 정확히 진단하고, 적절한 전처리와 모델링 기법을 적용하여 해결하는 역량을 배양하는 것이 본 프로젝트의 핵심적인 필요성이다.

2) 분석 목적 및 범위

본 프로젝트는 다양한 도메인과 문제 정의를 아우르는 **4가지 핵심 분석 과제**를 유기적으로 연계하여 수행함으로써, 머신러닝 방법론의 실무적 적용 능력을 검증하고자 한다. 구체적인 분석 범위는 다음과 같다.

첫째, 앙상블 기반 분류(Classification) 역량 강화: 캐글 산탄데르(Santander) 데이터와 신용카드 사기 검출 데이터를 활용하여 고차원 수치형 데이터의 특성 공학을 수행하고, 특히 심각한 클래스 불균형 문제를 해소하기 위한 SMOTE 기법과 최적의 앙상블 분류 모델 조합을 탐구한다.

둘째, 비지도학습(Clustering)을 통한 텍스트 인사이트 도출: Opinions 뉴스 및 의견 데이터를 활용하여 텍스트 토큰화, 벡터화, 차원 축소 과정을 거친 후 군집 분석을 수행하고, 비정형 데이터 속에서 유의미한 토픽과 패턴을 추출한다.

셋째, 대규모 텍스트 회귀(Regression) 및 통계적 가정 검증: 148만 건에 달하는 대규모 상품 텍스트 데이터를 대상으로 TF-IDF 기반의 고효율 희소행렬을 구축하고, 선형회귀 잔차 분석을 통해 모델의 가정을 검증하며 예측 성능을 고도화한다.

넷째, 자동화된 하이퍼파라미터 최적화(Optimization): 수동 탐색의 한계를 극복하고 베이지안 기반의 Hyperopt 기법을 도입하여 모델의 성능을 이론적 한계치까지 극대화한다.

결론적으로 본 프로젝트는 다양한 데이터 유형(수치형·정형·비정형 텍스트)과 문제 유형(회귀·분류·군집) 전반을 관통하는 체계적인 머신러닝 파이프라인을 구축함으로써, 실무 현장의 복잡한 문제를 창의적이고 효과적으로 해결할 수 있는 데이터 사이언티스트로서의 전문 역량을 확립하는 데 그 의의가 있다.

1.2 전체 보고서 구성 및 방법론 개요

본 보고서는 서로 다른 데이터 유형과 분석 목적을 가진 4개의 머신러닝 기반 분석 과제를 중심으로 구성하였다. 각 과제는 데이터의 특성과 문제 유형에 따라 적절한 분석 방법을 적용하되, **데이터 이해 및 탐색적 분석(EDA) → 데이터 전처리 및 특성 공학 → 머신러닝 모델링 → 성능 평가 및 최적화**라는 공통적인 분석 절차를 기반으로 수행하였다.

먼저 2장에서는 **캐글 산탄데르 데이터셋을 활용한 앙상블 분류 분석**을 수행한다. 고차원 수치형 변수로 구성된 데이터를 대상으로 결측치 및 변수 분포를 확인하고, 변수 간 관계와 데이터의 특성을 탐색한다. 이후 불필요하거나 정보량이 낮은 변수를 정제하고, 모델 학습에 적합하도록 데이터를 전처리한 뒤 다양한 앙상블 분류 모델을 적용하여 고객 거래에 대한 분류 예측을 수행한다. 모델별 성능을 비교하여 고차원 데이터에서 효과적인 분류 모델을 탐색하고, 최종적으로 최적 모델을 선정한다.

3장에서는 **신용카드 거래 데이터를 활용한 사기 거래 탐지 분석**을 수행한다. 해당 데이터는 정상 거래와 사기 거래 간의 비율 차이가 매우 큰 클래스 불균형 특성을 가지고 있으므로, 먼저 클래스 분포와 변수 특성을 분석하여 불균형 문제를 진단한다. 이후 SMOTE를 활용하여 학습 데이터의 소수 클래스 문제를 보정하고, 앙상블 기반 분류 모델을 적용한다. 단순 정확도뿐만 아니라 Precision, Recall, F1-score, ROC-AUC 등의 평가 지표를 종합적으로 활용하여 사기 거래 탐지에 적합한 모델을 비교·검증한다.

4장에서는 **Opinions 데이터를 활용하여 뉴스 및 의견 텍스트에 대한 비지도학습 기반 군집 분석**을 수행한다. 텍스트 데이터를 대상으로 불필요한 문자를 제거하고 토큰화 및 전처리를 수행한 후, TF-IDF 등의 방법을 이용하여 비정형 텍스트를 수치형 특성으로 변환한다. 이후 고차원 텍스트 특성의 구조를 파악하기 위해 차원 축소를 적용하고, 군집화 알고리즘을 통해 유사한 뉴스 및 의견을 그룹화한다. 또한 각 군집에서 빈번하게 나타나는 주요 단어와 토픽을 분석하여 군집별 특징과 의미를 해석한다.

5장에서는 **대규모 상품 텍스트 데이터를 활용한 회귀 분석**을 수행한다. 약 148만 건의 상품 데이터를 대상으로 상품명 및 관련 텍스트의 특성을 탐색하고, 텍스트 데이터를 TF-IDF 기반의 희소행렬로 변환하여 회귀 모델의 입력 변수로 활용한다. 이후 선형 기반 회귀모델을 중심으로 베이스라인 모델을 구축하고 예측값과 잔차를 분석하여 모델의 적합성과 통계적 가정을 검토한다. 마지막으로 Hyperopt를 활용한 하이퍼파라미터 최적화를 수행하여 모델의 예측 성능을 개선하고, 최적화 전후의 성능을 비교한다.

마지막으로 6장에서는 4개 분석 과제의 주요 결과를 종합적으로 정리하고, 각 데이터와 문제 유형에 따라 적용한 전처리 및 머신러닝 방법론의 특징과 성능 차이를 비교한다. 이를 통해 정형 수치 데이터, 불균형 분류 데이터, 비정형 텍스트 데이터 등 다양한 형태의 데이

터에 머신러닝 방법론을 적용하는 과정에서 도출된 주요 시사점을 정리하고, 향후 분석의 개선 방향을 제시한다.

전체적인 분석 과정은 다음과 같은 단계로 요약할 수 있다.

데이터 수집 및 이해 → EDA → 데이터 품질 검증 → 전처리 및 특성 공학 → 머신러닝 모델링 → 성능 평가 → 하이퍼파라미터 최적화 → 최종 모델 선정 및 결과 해석

이와 같은 체계적인 분석 절차를 통해 개별 모델의 단순한 성능 비교에 그치지 않고, 데이터의 특성과 문제 유형에 적합한 분석 방법을 선택하고 검증하는 **End-to-End 머신러닝 분석 역량**을 확보하는 것을 본 보고서의 방법론적 방향으로 설정하였다.

2. 캐글 산탄데르 데이터 앙상블 분류 분석

2.1 산탄데르 데이터셋 개요 및 탐색적 분석(EDA)

2.1.1 데이터셋 소개

본 분석에서는 Kaggle의 Santander Customer Satisfaction 데이터셋을 활용하였다. 해당 데이터셋은 은행 고객의 다양한 익명화 수치형 변수를 바탕으로 고객의 불만족 여부 (TARGET)를 예측하는 이진 분류 문제이다. 전체 데이터는 76,020건의 관측치와 ID·TARGET을 포함한 371개의 컬럼(float64 111개, int64 260개)으로 구성되어 있으며, 대부분의 변수가 var_로 시작하는 익명화된 수치형 특성이다

2.1.2 Target 분포 및 클래스 불균형

고객 만족도(TARGET) 변수의 분포를 확인한 결과, 만족 고객(0)이 약 96%, 불만족 고객(1)이 약 4% 수준으로 심각한 클래스 불균형이 존재함을 확인하였다.




그림 2-1. 고객 만족도(TARGET) 클래스 불균형 분포

고객 만족도(Target) 클래스 불균형 분포 - 만족 고객(0) 약 73,012명 vs 불만족 고객(1) 약 3,008명으로 분포되어 있다.

이러한 데이터 구조는 실제 은행 고객 데이터에서 흔히 나타나는 특성으로, 단순 Accuracy 만으로는 소수 클래스(불만족 고객)에 대한 예측력을 제대로 평가할 수 없어 이후 모델링 단계에서 SMOTE를 통한 클래스 불균형 보정과 Precision, Recall, F1-score, ROC-AUC 등 다각적인 평가 지표 활용이 필요함을 시사한다.

2.1.3 주요 변수별 구간별 불만족 비율

핵심 변수 후보들에 대해 값의 구간(Quantile)을 나누어 구간별 불만족 고객 비율을 살펴 보았다.




그림 2-2. 고객 나이(var15) 구간별 불만족 비율

고객 나이(var15)는 나이대가 높아질수록 불만족 비율이 뚜렷하게 상승하는 패턴을 보였다.(0.70%→6.99%)




그림 2-3. 최근 3개월 계좌 활동 월 수 구간별 불만족 비율

최근 3개월간 계좌 활동(거래) 월 수는 반대로 거래가 활발할수록(구간이 2~3개월) 불만족 비율이 낮아지는 경향(6.69% → 1.84%)을 나타냈다.




그림 2-4. 추정 계좌 잔고 구간별 불만족 비율

추정 계좌 잔고(자산 가치)는 잔고가 낮은 구간일수록 오히려 불만족 비율이 높게 나타나 (5.81% → 2.35%) 자산 규모와 불만족 간 음의 관계를 시사하였다.

2.1.4 만족/불만족 고객 간 분포 비교

만족 고객과 불만족 고객 간 주요 변수의 분포 차이를 Boxplot으로 비교하였다.




그림 2-5. 계좌 잔고(saldo_var30) 만족·불만족 그룹 Boxplot 비교

계좌 잔고(saldo_var30)의 경우 만족 고객은 넓은 범위(-400~700)의 분포를 보인 반면, 불만족 고객은 대부분 0 부근에 밀집된 좁은 분포를 나타내 계좌 활동성이 낮은 고객일수록 불만족 가능성이 높음을 시사한다.




그림 2-6. 고객 나이(var15) 만족·불만족 그룹 Boxplot 비교

고객 나이(var15)는 불만족 고객 그룹의 중앙값이 만족 고객 그룹보다 뚜렷하게 높게 나타나(중앙값 약 38세 vs 27세), 상대적으로 연령대가 높은 고객층에서 불만족이 더 빈번하게 발생하는 경향을 보였다.

2.1.5 변수 간 상관관계 및 만족/불만족 그룹 평균 비교

주요 변수 간 상관관계를 분석한 결과이다.




그림 2-7. 주요 변수 간 상관관계 히트맵

TARGET과 개별 변수 간 상관계수는 대체로 낮은 수준($|r| < 0.1$)으로 나타나 단일 변수만으로는 불만족 여부를 설명하기 어려우며, 다수 변수를 결합한 비선형적 모델링이 필요함을 확인하였다. 한편 saldo_var30과 saldo_var42는 0.79의 높은 상관관계를 보여 변수 간 중복 정보 가능성이 있음을 확인하였고, 이는 이후 변수 선택 단계에서 상관관계 기반 중복 변수 제거의 근거가 되었다.




그림 2-8. 만족·불만족 그룹별 주요 변수 평균 비교

만족·불만족 그룹별 주요 변수(전년 대비 계좌 납입/환급 금액 및 횟수 증감률 등)의 평균 값을 비교한 결과, 대부분의 변수에서 만족 고객 그룹의 평균값이 불만족 고객 그룹보다 높게 나타났다. 특히 13번·17번·44번 계좌의 납입·매입 관련 증감률 변수에서 두 그룹 간 격차가 뚜렷하여, 계좌 거래 활동성이 낮아질수록 불만족으로 이어질 가능성이 높다는 EDA 초기 가설을 뒷받침하였다.

2.1.6 EDA 결과 종합

EDA를 종합한 결과, 본 데이터셋은 313개(원본 371개 중 ID·TARGET 제외)의 익명화된 수치형 변수로 구성된 고차원 데이터이며 TARGET 클래스 불균형(약 96:4)이 뚜렷하게 나타났다. 고객 나이·계좌 활동성·계좌 잔고 등 일부 변수에서 불만족 비율과의 관계가 확인되었으나 개별 변수의 설명력은 제한적이어서, 다수 변수를 결합한 앙상블 기반 모델링과 체계적인 변수 선택이 필요함을 확인하였다.

2.2 고차원 수치형 데이터 전처리 및 특성 공학

2.2.1 후보 변수 선정

초기 313개의 설명변수를 대상으로 통계적 방법과 머신러닝 기반 방법을 함께 적용하여 변수 선택을 수행하였다. 적용한 방법은 다음과 같다.

- 가. 통계적 변수 선택 (통계검정 기반 유의 변수 추출)
- 나. 상관관계 기반 중복 변수 제거
- 다. LASSO 변수 선택
- 라. Random Forest 변수 중요도 기반 선택
- 마. XGBoost 변수 중요도 기반 선택

서로 다른 변수 선택 방법에서 반복적으로 선택되는 변수를 교차 확인하여 모델에 중요한 변수들을 선별하였다. 상관관계가 높은 변수들은 그룹화하여 각 그룹에서 대표 변수를 선정하는 방식으로 중복 정보를 제거하였다.

2.2.2 통계적 변수 선택

통계적 변수 선택은 만족·불만족 두 집단 간 분포 차이를 검정하는 Mann-Whitney U 검정을 통해 수행하였다. 다중검정으로 인한 오류를 통제하기 위해 Benjamini-Hochberg 방식의 FDR(False Discovery Rate) 보정을 적용하였으며, 그 결과 전체 313개 변수 중 132개 변수가 보정 후에도 통계적으로 유의한 차이를 보였다. 특히 **var15**, **num_meses_var5_ult3**, **saldo_var30**, **num_var30**, **saldo_var5** 등이 상대적으로 큰 효과크기(Rank-biserial correlation)를 나타내 TARGET과의 연관성이 뚜렷하였다.

	variable	p_value	p_adjusted	effect	abs_effect	significant
0	var15	4.376503e-187	3.424614e-185	0.400563	0.400563	True
1	num_meses_var5_ult3	5.376273e-204	8.413867e-202	-0.378243	0.378243	True
2	saldo_var30	1.729939e-158	6.768385e-157	-0.365743	0.365743	True
3	num_var30	4.999099e-199	5.215727e-197	-0.342330	0.342330	True
4	saldo_var5	3.835850e-141	1.334023e-139	-0.341239	0.341239	True

그림 2-9. 통계적 검정 기반 변수 유의성 결과 상위 5개(p-value, effect size)

2.2.2 상관관계기반 변수 선택

상관관계 기반 중복 변수 제거 단계에서는 연속형 변수 간 상관계수를 산출하여 $|r| \geq 0.95$ 인 변수쌍을 동일 정보군으로 그룹화(Union-Find 방식)하였다. 각 그룹 내에서는 TARGET에 대한 효과크기가 가장 큰 변수를 대표 변수로 선정함으로써 다중공선성으로 인한 중복 정보를 완화하였다.

group	size	representative	representative_effect	variables
37	38	10	num_var26_0	0.021170 num_var26_0, num_var26, ind_var26_0, ind_var26...
25	26	9	saldo_var13_corto	0.034137 saldo_var13_corto, saldo_medio_var13_corto_ult...
56	57	8	saldo_var40	0.003785 saldo_var40, ind_var40, ind_var39, num_var40, ...
27	28	6	saldo_var12	0.032739 saldo_var12, num_var12, ind_var12, saldo_medio...
28	29	6	num_meses_var8_ult3	0.030689 num_meses_var8_ult3, ind_var8, num_var8, saldo...
49	50	5	num_var13_largo_0	0.010079 num_var13_largo_0, ind_var13_largo_0, saldo_va...
20	21	5	saldo_var13	0.043844 saldo_var13, ind_var13, num_var13, num_var13_0...
35	36	4	imp_op_var41_efect_ult1	0.025264 imp_op_var41_efect_ult1, imp_op_var39_efect_ul...

그림 2-10. 상관관계 기반 중복 변수 그룹화 결과

2.2.3 LASSO 변수 선택

LASSO 변수 선택은 L1 정규화를 적용한 Logistic Regression을 통해 수행하였으며, 회귀

계수가 0으로 축소되지 않은 변수를 선택 변수로 간주하였다. 그 결과 전체 313개 변수 중 109개 변수가 선택되어 원래 변수 구조의 약 65% 수준으로 축소되었고, var15, var38, num_meses_var5_ult3, ind_var13 등이 상대적으로 큰 절대 계수를 보여 고객 불만족 예측과의 관련성이 높게 나타났다.



	coefficient
var15	0.492672
var38	-0.477429
num_meses_var5_ult3	-0.469501
ind_var13	-0.406579

그림 2-11. LASSO 변수 선택 결과(절대 계수 상위)

2.2.4 Tree 기반 변수 선택

Random Forest와 XGBoost는 각 모델을 학습한 뒤 산출한 Feature Importance를 기준으로, 중요도 상위 20%에 해당하는 변수를 선택 변수로 채택하는 트리 기반 변수 선택을 수행하였다. 두 모델 모두 비선형적인 변수 관계와 변수 간 상호작용을 반영할 수 있어, 통계적 검정 및 LASSO와는 다른 관점에서 변수 중요도를 평가하였다.

	importance
var15	0.158532
saldo_var30	0.071476
saldo_var5	0.066157
saldo_var42	0.047282
saldo_medio_var5_ult3	0.045476
saldo_medio_var5_hace2	0.040095
num_meses_var5_ult3	0.034261
saldo_medio_var5_ult1	0.032863
num_var42	0.029494
saldo_medio_var5_hace3	0.025622
num_var4	0.024881
num_var30	0.023324
num_var5	0.023273
ind_var30	0.022680

그림 2-12. Random Forest 변수 중요도(Feature Importance)

	importance
ind_var30	0.123872
num_var4	0.051711
saldo_var30	0.037237
ind_var26_0	0.031315
ind_var13_0	0.027596
var15	0.026210
ind_var30_0	0.017943
num_var35	0.016867
num_var5	0.016434
ind_var13	0.014192
ind_var10cte_ult1	0.012482
num_var42_0	0.012048
imp_op_var41_efect_ult1	0.010384
num_var22_ult1	0.010321
ind_var8_0	0.009596

그림 2-13. XGBoost 변수 중요도(Feature Importance)

네 가지 방법(통계검정 132개, LASSO 109개, Random Forest 63개, XGBoost 63개)으로 선택된 변수 집합을 비교한 결과, 네 가지 방법 모두에서 공통적으로 선택된 변수는 15개였다. 이는 단일 변수 선택 방법에 의존하지 않고 서로 다른 통계적·머신러닝 방법에서 일관되게 중요성이 확인된 변수가 존재함을 의미하며, 이후 최종 Feature Set 구성의 핵심 근거가 되었다.

2.3 앙상블 기법을 활용한 고객 거래 분류 예측

2.3.1 Base Logistic Regression

위에서 선택한 공통 변수를 통해 SMOTE를 적용한 Train 데이터로 Logistic Regression Baseline을 구축하고, 원본 클래스 분포를 유지한 Validation 데이터에서 평가하였다. ROC-AUC는 0.7888, PR-AUC는 0.1234를 기록했으며, 불만족 고객에 대한 Recall은 0.7342로 나타났다. 이는 실제 불만족 고객의 약 73%를 사전에 식별할 수 있음을 의미한다. 다만 Precision은 0.0864로 낮아 상당수의 만족 고객을 불만족 고객으로 분류하는 한계가 확인되었다.

따라서 현재 모델은 고객관리 대상자를 넓게 탐색하는 1차 screening 용도로는 활용 가능하지만, 실제 운영 단계에서는 Threshold 조정을 통해 Recall과 Precision 간 trade-off를 검토할 필요가 있다.

2.3.2 Base XGBoost

Base XGBoost는 Logistic Regression 대비 ROC-AUC가 0.7888에서 0.8172로, PR-AUC가 0.1234에서 0.1648로 향상되었다. 또한 Precision과 F1-score도 개선되어 불만족 고객을 보다 정밀하게 식별하는 데 유리한 결과를 보였다. 반면 Recall은 0.7342에서 0.5166으로 감소하여, 실제 고객관리에서는 모델의 기본 threshold 0.5를 그대로 사용하기보다 목적에 맞는 Threshold 최적화가 필요함을 확인하였다.

다음은 XGBoost Hyperparameter Tuning 과 Base XGBoost 결과를 비교해보았다.

2.3.3 XGBoost Hyperparameter Tuning

기존 XGBoost 모델의 성능을 개선하기 위해 교차검증 과정 내부에서 SMOTE가 적용되

도록 Pipeline을 구성하고, RandomizedSearchCV를 이용해 하이퍼파라미터를 탐색하였다. 기존 방식과 달리 각 교차검증 Fold의 학습 데이터에만 SMOTE를 적용하여 데이터 누수 가능성이 최소화하였다.

그 결과 최적 모델의 Validation ROC-AUC는 0.8208, PR_AUC는 0.1677로 나타났다. 기존 XGBoost의 ROC-AUC 0.8172, PR-AUC 0.1648보다 모두 개선되었다.

Threshold 0.5 기준 Precision은 0.1681, Recall은 0.5664, F1-score는 0.2593으로 나타났다. 특히 Recall이 기존 XGBoost의 0.5166에서 0.5664로 상승하여 실제 불만족 고객을 더 많이 탐지할 수 있게 되었다. 반면 Precision은 다소 감소하여 정상 고객을 불만족 고객으로 분류하는 False Positive가 증가하였다.

본 프로젝트에서는 불만족 고객을 사전에 식별하여 대응하는 것이 중요하므로, 단순 정확도보다는 ROC-AUC와 PR-AUC를 중심으로 모델의 판별력을 평가하고, 이후 Validation 데이터를 활용하여 비즈니스 목적에 적합한 예측 Threshold를 별도로 결정하였다.

	threshold	precision	recall	f1	TN	FP	FN	TP
40	0.70	0.206337	0.443522	0.281646	13575	1027	335	267
33	0.63	0.194780	0.508306	0.281638	13337	1265	296	306
37	0.67	0.205011	0.448505	0.281397	13555	1047	332	270
39	0.69	0.205701	0.443522	0.281053	13571	1031	335	267
44	0.74	0.208367	0.430233	0.280759	13618	984	343	259
41	0.71	0.205723	0.441860	0.280739	13575	1027	336	266
43	0.73	0.207502	0.431894	0.280323	13609	993	342	260
36	0.66	0.202823	0.453488	0.280287	13529	1073	329	273
38	0.68	0.204424	0.445183	0.280188	13559	1043	334	268
35	0.65	0.202673	0.453488	0.280144	13528	1074	329	273

그림 2-14. XGBoost Threshold별 Precision·Recall·F1 결과

Tuned XGBoost의 Validation 예측 확률을 대상으로 Threshold를 조정한 결과, F1-score는 Threshold 0.70에서 0.2816으로 가장 높게 나타났다. 해당 Threshold에서 Precision은

20.63%, Recall은 44.35%였으며, 실제 불만족 고객 602명 중 267명을 탐지하였다.

기본 Threshold 0.50과 비교하면 Threshold를 0.70으로 높였을 때 Precision은 16.81%에서 20.63%로 개선되고 F1-score도 0.2593에서 0.2816으로 상승하였다. 동시에 False Positive는 1,687건에서 1,027건으로 감소하였다. 반면 Recall은 56.64%에서 44.35%로 감소하여 실제 불만족 고객을 놓치는 비율은 증가하였다.

따라서 Threshold 0.70은 불만족 고객을 무조건 많이 탐지하기보다는, 예측의 정밀도와 Recall 사이의 균형을 고려한 F1-score를 최대화하는 기준으로 해석할 수 있다. 다만 본 프로젝트의 목적이 불만족 고객의 사전 탐지에 있으므로, 최종 Threshold는 F1-score뿐 아니라 Recall과 False Negative 발생 규모를 함께 고려하여 결정하였다.

2.4 모델 성능 평가 및 최적화 결과 분석

2.4.1 최종 XGBoost 모델 성능

최종 XGBoost 모델은 통계적 변수 선택과 LASSO, Random Forest, XGBoost 기반 변수 선택 결과를 종합하여 구성한 15개 변수를 사용하였다. 또한 클래스 불균형 문제를 해결하기 위해 SMOTE를 적용하고, 교차검증 과정 내부에서만 오버샘플링이 수행되도록 Pipeline을 구성하여 데이터 누수 가능성을 최소화하였다.

RandomizedSearchCV를 이용한 하이퍼파라미터 최적화 결과 Validation ROC-AUC는 0.8208, PR-AUC는 0.1677을 기록하였다. 이후 Validation 데이터에서 예측 Threshold를 탐색하여 F1-score가 가장 높은 0.70을 최종 Threshold로 선정하였다.

최종 모델을 Train과 Validation 데이터로 재학습한 후 독립적인 Test 데이터에 적용한 결과, ROC-AUC 0.8172, PR-AUC 0.1496을 기록하였다. Threshold 0.70 기준 Precision은 18.77%, Recall은 43.26%, F1-score는 0.2618로 나타났다.

Test 데이터의 실제 불만족 고객 601명 중 260명을 정확하게 탐지하여 약 43.3%의 Recall을 달성하였다. 반면 341명의 불만족 고객은 정상 고객으로 분류되었으며, 정상 고객 중 1,125명은 불만족 고객으로 잘못 분류되었다.

본 모델은 불만족 고객을 완벽하게 분류하는 것보다 전체 고객 중 상대적으로 불만족 가능성이 높은 고객을 선별하여 사전 대응 대상군을 구성하는 목적에 적합하다. 특히 불만족 고객의 비율이 약 4%로 매우 낮은 상황에서 ROC-AUC 0.8172와 PR-AUC 0.1496을 기록함으로써 단순한 무작위 선별보다 효과적인 고객 위험도 분류가 가능함을 확인하였다.

또한 Validation ROC-AUC 0.8208과 Test ROC-AUC 0.8172가 유사하게 나타나 특정 데이터에 과도하게 의존하지 않고 일정 수준의 일반화 성능을 확보한 것으로 판단하였다.

2.4.2 SHAP

SHAP Summary Plot을 통해 XGBoost 모델의 변수별 예측 기여도를 분석하였다.




그림 2-15. SHAP Summary Plot (XGBoost 변수별 예측 기여도)

분석 결과 var15가 가장 높은 영향력을 보였으며, 다음으로 ind_var30, num_meses_var5_ult3, saldo_medio_var5_hace3, saldo_var30 등의 순으로 모델 예측에 중요한 영향을 미치는 것으로 나타났다. 특히 var15는 SHAP 값의 분포 범위가 가장 넓어 고객별 예측 결과에 미치는 영향력이 큰 변수로 확인되었다.

또한 변수의 값에 따른 영향 방향을 살펴보면 var15는 높은 값이 대체로 양(+)의 SHAP 값을 나타내 거래 고객으로 분류될 가능성을 높이는 방향으로 작용한 반면, ind_var30과 num_meses_var5_ult3는 높은 값이 주로 음(-)의 SHAP 값을 나타내 거래 고객 예측을 낮추는 방향으로 작용하였다. 반면 saldo_medio_var5_hace3 등 일부 변수는 높은 값과 낮은 값이 양쪽 SHAP 영역에 혼재하여 단순한 선형 관계보다는 다른 변수와의 상호작용 및 비선형적 관계가 존재할 가능성을 보여준다.

종합적으로 var15를 중심으로 일부 잔액 및 거래 관련 변수가 고객 거래 여부 예측에 중요한 역할을 하는 것으로 확인되었으며, SHAP 분석을 통해 단순한 변수 중요도뿐만 아니라 각 변수값이 예측 결과에 미치는 방향까지 확인할 수 있었다.

2.4.3 통계모델 vs 머신러닝 변수 선택 통합

수 선택의 안정성을 검증하기 위해 통계적 유의성 검정, LASSO, Random Forest, XGBoost의 네 가지 방법을 비교하였다. 전체 후보 변수 313개 중 여러 방법에서 반복적으로 선택되는 변수를 확인하고, 최종적으로 사용한 15개 변수와의 일치 여부를 검증하였다.

분석 결과, 최종 Feature Set은 총 15개 변수로 구성되었으며, 이 중 13개가 통계검정, LASSO, Random Forest, XGBoost의 네 가지 방법에서 모두 선택되었다. 이는 최종 변수의 약 86.7%가 특정 변수 선택 방법에만 의존하지 않고 서로 다른 통계적·머신러닝 방법에서 일관되게 중요하게 평가되었음을 의미한다.

특히 'ind_var13', 'ind_var30', 'num_var22_ult1', 'num_var35', 'num_var45_ult1', 'saldo_var30', 'saldo_var42', 'saldo_var5', 'var15', 'var38' 및 'saldo_medio_var5' 계열 변수들은 여러 방법에서 반복적으로 선택되어 고객 만족도 예측에 있어 상대적으로 안정적인 설명력을 가진 변수 후보로 판단하였다.

반면 최종 15개 변수 중 'num_mese_var5_ult3'와 'num_var42_0'은 모든 방법에서 공통적으로 선택되지는 않았다. 이는 변수 선택 방법에 따라 변수의 중요도 평가가 달라질 수 있음을 보여준다. 특히 통계적 유의성은 변수와 Target 간의 관계를 평가하는 반면, LASSO는 정규화를 통한 선형 변수 선택을 수행하고, Random Forest와 XGBoost는 비선형 관계와 변수 간 상호작용까지 고려하기 때문에 각 방법의 결과가 완전히 일치할 필요는 없다.

따라서 본 프로젝트에서는 단일 모델의 중요도만으로 변수를 선정하지 않고, 통계적 검정과 선형, 비선형 머신러닝 모델의 결과를 교차 검증하였다. 그 결과 최종 15개 변수 중 대부분이 네 가지 방법에서 공통적으로 선택되어, 최종 Feature set의 변수 선정이 특정 알고리즘에 과도하게 의존하지 않았음을 확인하였다.

2.4.4 결론

본 분석은 313개의 초기 변수를 대상으로 통계적 유의성 검정, 상관관계 기반 중복 제거, LASSO, Random Forest, XGBoost를 단계적으로 적용하여 최종 15개의 변수를 선정하였다.

또한 약 4% 수준의 불만족 고객 비율로 인해 발생하는 심각한 클래스 불균형 문제를 SMOTE를 통해 학습 데이터에서 보완하였다. 이후 Logistic Regression을 baseline으로 설정하고 XGBoost와 비교하여 모델 성능을 검증하였다.

최종적으로 Tuned XGBoost는 Test 데이터에서 ROC-AUC 0.8172를 기록하여 만족 고객과 불만족 고객을 비교적 효과적으로 구분하였다. 또한 Threshold를 0.70으로 조정함으로써 Precision 0.1877, Recall 0.4326, F1-score 0.2618을 달성하였다.

따라서 본 모델은 고객 불만족 여부를 단순히 분류하는 것보다, 불만족 가능성이 높은 고객을 사전에 식별하고 해당 고객에게 우선적으로 관리 또는 예방적 대응을 수행하기 위한 분석 도구로 활용하는 것이 적절하다.

3. 캐글 신용카드 사기 검출

3.1 신용카드 사기 데이터 특성 및 클래스 불균형 문제 진단

3.1.1 데이터 셋 개요

본 분석에는 Kaggle의 Credit Card Fraud Detection 데이터셋을 활용하였다. 해당 데이터셋은 유럽 카드 소지자의 실제 거래 내역을 기반으로 하며, 개인정보 보호를 위해 원본 변수는 PCA(주성분분석)로 비식별화되어 V1~V28이라는 28개의 익명화된 수치형 변수로 제공된다. 여기에 원본 그대로 보존된 Time(첫 거래 이후 경과 초), Amount(거래 금액), 그리고 목표변수 Class(0=정상, 1=사기)를 더해 총 31개 컬럼, 284,807건의 거래로 구성되어 있다.

3.1.2 데이터 품질 검증

결측치와 음수 이상값이 전혀 없어 데이터의 기본적인 무결성은 우수한 것으로 확인되었다. 다만 1,081건의 완전 중복 행이 발견되었는데, 이는 시스템의 중복 로깅일 수도 있으나 동일 카드로 짧은 시간 내 반복 시도된 사기 패턴일 가능성도 배제할 수 없다. 이에 따라 중복 데이터를 무조건 제거하기보다, 학습(Train) 데이터에서는 실제 거래 분포 보존을 위해 중복을 유지하고, 검증·평가(Validation/Test) 데이터에서는 평가 공정성을 위해 중복을 제거하는 전략을 채택하였다.

3.1.3 클래스 불균형 진단

정상 거래와 사기 거래의 비율이 약 578:1에 달하는 극단적인 클래스 불균형이 확인되었다(그림 04-1). 이러한 구조에서는 모델이 모든 거래를 "정상"으로만 예측해도 99.8%가 넘

는 정확도(Accuracy)를 얻을 수 있어, Accuracy 지표 자체가 사실상 무의미해진다. 따라서 본 분석에서는 이후 모델링·평가 단계에서 **Recall(재현율)**과 소수 클래스에 민감한 **PR-AUC(Precision-Recall AUC)**를 핵심 평가지표로 설정하고, SMOTE 등 클래스 불균형 보정 기법의 적용을 전제로 파이프라인을 설계하였다.

3.1.4 주요 변수 분포 특성

거래 금액(Amount): 왜도(Skewness)가 약 17.00으로 극심한 우측 편포를 보였다. 대다수 거래가 소액에 몰려 있고 일부 고액 거래가 꼬리를 길게 늘어뜨리는 구조로, 이후 모델 학습 시 표준화(Standardization) 또는 로버스트 스케일링(Robust Scaling) 처리가 필요함을 시사한다.

거래 시간(Time): 초 단위 Time을 시간 단위로 환산해 분포를 살펴본 결과(그림 04-3), 48시간(이틀) 동안 뚜렷한 일주기(Diurnal) 패턴이 두 번 반복되는 것을 확인하였다. 새벽 시간대에는 거래량이 크게 감소했다가 낮 시간대에 다시 증가하는 흐름이 두 주기 모두에서 일관되게 나타나, 시간대 정보가 정상/사기 거래를 구분하는 데 보조적인 단서가 될 수 있음을 시사한다.

주요 PCA 변수(V1, V4, V11, V14): 정상 그룹과 사기 그룹 간 확률밀도(KDE)를 비교한 결과(그림 04-4), V4, V11, V14에서 두 그룹의 분포가 육안으로도 뚜렷하게 분리되는 것을 확인하였다. 특히 V14는 정상 그룹이 0 부근에 뾰족하게 몰려있는 반면 사기 그룹은 음수 방향으로 넓게 퍼져 있어 판별력이 매우 높아 보인다. V1은 두 그룹의 중심(mode)은 비슷하나 사기 그룹의 분포가 음수 방향으로 훨씬 넓게 퍼져 있어 상대적으로 분리도가 약한 편이다.




그림 3-1. 클래스 불균형·거래 금액 분포·거래 시간 분포

3.1.5 변수 간 상관관계

Amount, Class와 V1~V14(가독성을 위해 일부만 표시) 간 상관관계를 분석한 결과(그림 04-5), Class와 개별 변수 간 상관계수는 V14(-0.30), V12(-0.26), V10(-0.22) 등으로 **모두 약한~중간 수준($|r| < 0.3$)**에 그쳤다. 이는 단일 변수만으로는 사기 여부를 설명하기 어려우며, 다수 변수를 결합한 비선형적 분류 모델이 필요함을 뒷받침한다. 한편 V1과 Amount의 상관계수는 -0.23으로 낮은 수준이었으며, 표에 포함된 변수 쌍 중 상관계수 절대값이 0.7을 넘는 조합은 없어 다중공선성에 대한 초기 우려는 낮은 것으로 나타났다(정식 VIF 진단은 이후 단계에서 별도로 다룬다).




그림 3-2. Amount·Class·V1~V14 변수 간 상관관계 히트맵

3.1.6 소결

종합하면, 본 데이터셋은 (1) 결측치, 이상값이 없는 양호한 데이터 품질을 갖추었으나 1,081건의 중복 행 처리가 필요하고, (2) 정상:사기 = 약 578:1에 달하는 극단적 클래스 불균형이 존재하여 Accuracy가 아닌 Recall, PR-AUC 중심의 평가체계가 요구되며, (3) V14, V11, V4 등 일부 PCA 변수에서 두 클래스 간 뚜렷한 분포 분리가 관찰되어 이후 통계적 검증 및 모델링 단계에서 핵심 판별 변수로 작용할 가능성이 높다는 점을 확인하였다.

3.2 통계적 추론 및 변수 간 다중공선성 진단

3.2.1 정규성 검정 및 비모수 검정 채택 근거

Amount 의 왜도는 약 17.00에 달하며, V1~V28의 주요 변수들도 대부분 0에서 크게 벗어난 비대칭 분포를 보였다.

이처럼 정규성을 가정할 수 없는 상태에서는, 표본 규모가 284,807건에 달해 Shapiro-Wilk 등 공식적인 정규성 검정 자체가 사실상 무의미해진다는 점도 함께 고려하였다(표본이 크면 극히 미세한 정규성 이탈에도 검정이 기계적으로 "비정규"를 반환하기 때문이다).

따라서 왜도 측정을 통한 실질적 분포 특성 진단에 근거하여, 두 집단(정상 vs 사기)의 평균 차이를 검정하는 모수적 방법(t-검정) 대신 중앙값 차이를 검정하는 비모수 방법인 Mann-Whitney U 검정을 채택하였다.

3.2.2 Mann-Whitney U 검정 및 효과크기(Cohen's d)

29개 변수에 대해 정상 거래군과 사기 거래군 간 Mann-Whitney U 검정을 실시하고, 차이의 실질적 크기를 나타내는 Cohen's d를 함께 산출하였다. 다중검정으로 인한 1종 오류를 통제하기 위해 Benjamini-Hochberg FDR(False Discovery Rate) 보정을 적용하였다.

	Variable	MW_Statistic	p_value	Cohen_d	p_adjusted	Significant_FDR
0	V17	113052725.0	9.219384e-124	8.317624	2.430565e-123	True
1	V14	132771289.0	1.471581e-260	7.643639	4.267584e-259	True
2	V12	131075998.0	8.416027e-247	6.499801	8.135492e-246	True
3	V10	127861066.0	9.611131e-222	5.350007	5.574456e-221	True
4	V16	118499273.0	1.808172e-156	4.826913	6.554625e-156	True
5	V3	127583455.0	1.211048e-219	4.735605	5.853399e-219	True
6	V7	116915822.0	1.464234e-146	4.590445	4.246278e-146	True
7	V11	11458771.0	4.910592e-226	3.775043	3.560179e-225	True
8	V4	8636598.0	3.625904e-248	3.242492	5.257561e-247	True
9	V18	103851068.0	2.648962e-77	2.701469	5.121326e-77	True

그림 3-3. Mann-Whitney U 검정 및 Cohen's d 효과크기 상위 10개 변수

FDR 보정 후에도 상위 10개 변수 전부 Significant_FDR = True로 나타났다. Cohen's d의 일반적 해석 기준(0.2=작음, 0.5=중간, 0.8=큼)에 비추어 보면, 이 변수들의 효과크기 (2.7~8.3)는 "큰 효과" 기준을 최소 3배에서 최대 10배 이상 상회하는 극단적인 수준이다.

p-값이 이렇게 극단적으로 작게 나온 데는 표본 크기가 매우 크다는 사실도 상당 부분 기여한다. 표본이 크면 아주 작은 차이도 통계적으로 "유의함"으로 판정되기 쉽기 때문에, p-값 자체보다는 Cohen's d(효과크기)가 실질적 판별력을 뒷받침하는 더 중요한 근거다.

이 데이터셋의 경우 p-값과 효과크기가 함께 극단적인 값을 보였기 때문에, 통계적 유의성과 실질적 유의성이 이례적으로 일치하는 강력한 근거를 확보했다고 해석할 수 있다.




그림 3-4. 변수별 효과크기(Cohen's d) 상위 10개

3.2.3 VIF(분산팽창요인) 다중공선성 진단

	Feature	VIF
0	Amount	11.499791
1	V2	3.869377
2	V5	2.753075
3	V7	2.510165
4	Time	2.339084
5	V20	2.233934
6	V1	1.621694
7	V6	1.522122
8	V3	1.255585
9	V23	1.149268

그림 3-5. 변수별 VIF(분산팽창요인) 상위 10개

일반적 기준($VIF > 10$)에서 심각한 다중공선성으로 분류되는 변수는 Amount(11.50) 하나 뿐이었으며, 그 외 변수는 모두 4 미만으로 매우 안정적이었다. 이는 V1~V28이 PCA(주성분분석)로 변환된 변수라는 근본적 특성에서 기인한다 — PCA는 정의상 주성분들이 서로 직교(orthogonal)하도록 변환하므로, 이 변수들 사이에는 원천적으로 강한 선형 상관관계가 존재하기 어렵다. 반면 Amount는 PCA 변환을 거치지 않은 원본 변수이기 때문에 다른 변수들과 자연스럽게 일부 정보를 공유하며 VIF가 상대적으로 높게 나타난 것으로 판단된다.

다만 11.50은 기준치(10)를 근소하게 상회하는 수준이고, 3.3절에서 이미 적용한 RobustScaler 스케일링을 통해 실질적인 모델링 리스크는 완화된다.

3.2.4 소결

본 절에서는 (1) 비모수 검정(Mann-Whitney U)과 효과크기(Cohen's d)를 통해 V17, V14, V12, V10, V16 등이 정상·사기 거래를 통계적으로, 그리고 실질적으로도 매우 큰 폭으로 구분 짓는 핵심 변수임을 확인하였고, (2) 큰 표본 크기가 p-값을 과도하게 작게 만들 수 있다는 점을 인지하여 효과크기를 판단의 중심에 두었으며, (3) 상관계수와 효과크기라는 서로 다른 두 접근이 동일한 핵심 변수 집합을 가리킨다는 점에서 결과의 견고성(robustness)을 교차검증하였고, (4) VIF 진단을 통해 Amount 외에는 다중공선성 우려가 낮은 안정적 구조임을 확인하였다. 이 절에서 도출된 핵심 판별 변수 목록(V17, V14, V12, V10, V16, V3, V7, V4 등)은 이후 3.5절(로지스틱 회귀 오즈비 분석)과 3.7절(SHAP 해석)에서 실제 모델이 학습한 변수 중요도와 다시 한번 교차 검증하는 기준으로 활용된다.

3.3 불균형 데이터 보정 및 전처리

3.3.1 스케일링

V1 ~ V28 은 이미 PCA 변환을 거쳐 정규화된 스케일을 갖고 있으므로 별도 처리를 하지 않았다. 반면 원본 형태로 남아있는 Amount(거래금액)와 Time(시간)은 스케일이 다른 변수들과 크게 달라 모델 학습을 저해할 수 있어 스케일링이 필요하다.

Amount의 왜도가 약 17.00에 달할 만큼 이상치가 많은 분포이므로, 평균과 표준편차 기반의 StandarScaler 대신 중앙값과 IQR을 기준으로 동작해 이상치 영향을 덜 받는 RobustScaler 를 적용하였다. 변환된 값은 각각 Amount_Scaled, Time_Scaled 라는 새 컬럼으로 추가하고, 원본 Amount, Time은 제거하였다.

3.3.2 학습/평가 데이터 분할

전체 284,807건을 Train 80% / Test 20%로 분할하되, 원본 데이터에서 관찰된 극단적 클래스 불균형(정상:사기 578:1)이 분할 과정에서 한쪽으로 쏠리지 않도록 stratify=y 옵션을 적용한 층화추출(Stratified Split)을 실시하였다.

```
[전처리 및 데이터 분할 완료]
- 전체 데이터 세이프: (284807, 31)
- 훈련 세트(Train X): (227845, 30), 사기 비율: 0.1729%
- 테스트 세트(Test X): (56962, 30), 사기 비율: 0.1720%
```

그림 3-6. Train/Test 분할 결과 및 사기 비율 검증

두 세트 간 사기 비율 차이가 0.0009%p에 불과해, 원본 데이터의 불균형 구조가 분할 후에도 왜곡 없이 그대로 유지되었음을 확인하였다.

3.3.3 SMOTE를 이용한 클래스 불균형 보정

학습 데이터(Train)만을 대상으로 **SMOTE(Synthetic Minority Over-sampling Technique)**를 적용하여 소수 클래스(사기 거래)를 합성적으로 오버샘플링하였다. SMOTE는 소수 클래스 샘플들 사이를 보간(interpolation)하여 새로운 가상의 사기 거래 데이터를 생성하는 기법으로, 단순 복제(Random Oversampling)와 달리 특징 공간상에서 더 다양한 사기 패턴을 학습할 수 있게 해준다.

- 적용 대상: Train 세트에만 적용 (Test 세트는 실제 분포를 보존하기 위해 원본 그대로 유지)
- 샘플링 전략: 기본 옵션(sampling_strategy='auto')을 사용해 소수 클래스를 다수 클래스와 동일한 건수까지 오버샘플링

중요한 점은 SMOTE를 Test 세트에는 절대 적용하지 않았다는 것이다. 만약 Test 세트까지 오버샘플링하면 합성된(가짜) 사기 데이터가 평가 지표에 섞여 실제 모델 성능이 과대평가되는 데이터 누수(Data Leakage) 문제가 발생하기 때문이다.

이는 Train 세트에서만 실제 거래 데이터를 기반으로 합성 샘플을 만들고, Test 세트는 끝까지 원본 그대로 두어 실제 운영 환경과 동일한 조건에서 모델을 평가하기 위한 필수적인 절차이다.

3.4 베이스라인 모델 평가

3.4.1 개요

통계적 추론과 전처리, SMOTE를 통해 데이터의 통계적 특성과 전처리 파이프라인을 확립하였다. 어떤 불균형 보정 기법도 적용하지 않은 순수 기본 모델을 학습하여, 이후 도입할 다양한 앙상블 모델, 불균형 처리 기법의 성능 개선 효과를 비교할 기준점을 설정한다.

베이스라인 모델로는 해석이 용이하고 구현이 간단한 Logistic Regression을 선정하였다.

3.4.2 평가지표 선정 근거

정상:사기 비율이 약 578:1에 달하는 극단적 불균형 환경에서는, 전체 거래를 "정상"으로만 예측해도 Accuracy가 99.8%를 넘길 수 있어 Accuracy는 평가지표로서 실질적 의미를 상실한다. 따라서 본 평가에서는 다음 지표를 핵심으로 삼았다.

- ROC-AUC: 임계값 전반에 걸친 분류 성능의 종합적 지표
- PR-AUC(Precision-Recall AUC): 소수 클래스(사기) 탐지 성능에 민감하게 반응하는 지표로, 불균형 데이터에서 ROC-AUC보다 더 신뢰할 수 있는 기준
- Recall(재현율): 실제 사기 거래 중 모델이 놓치지 않고 잡아낸 비율 — 사기 누락(False Negative)은 금전적 손실로 직결되므로 특히 중요

3.4.3 성능 지표 결과

```
[1] 베이스라인 모델(logistic)

[2] 베이스라인 모델 평가 결과:
- ROC-AUC : 0.9582
- PR-AUC  : 0.7391

[Classification Report]
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	56864
1	0.82	0.64	0.72	98
accuracy			1.00	56962
macro avg	0.91	0.82	0.86	56962
weighted avg	1.00	1.00	1.00	56962

그림 3-7. 베이스라인 모델 평가 결과(ROC-AUC·PR-AUC·Classification Report)

ROC-AUC는 0.9582로 매우 높게 나타났으나, 이는 압도적으로 많은 정상 거래(56,864건)를 거의 완벽하게 분류한 결과에 크게 의존한 수치다. 실제 사기 탐지 역량을 대변하는 PR-AUC는 0.7391로, ROC-AUC보다 상당히 낮게 측정되어 향후 개선의 여지가 뚜렷하게 남아있음을 보여준다.

3.4.4 혼동행렬(Confusion Matrix) 분석

```
[Confusion Matrix]
[[56850  14]
 [  35  63]]
```

그림 3-8. 베이스라인 모델 혼동행렬(Confusion Matrix)

전체 사기 거래 98건 중:

- 정탐(True Positive): 63건 — 모델이 정확히 사기로 잡아낸 거래

- 미탐지(False Negative): 35건 — 실제 사기임에도 정상으로 오분류(전체 사기의 약 36%)
- 오탐지(False Positive): 14건 — 정상 거래를 사기로 잘못 예측 (전체 정상 거래의 0.025%에 불과해 매우 낮음)

Precision(0.82)이 상대적으로 높다는 것은 "사기로 예측한 것 중 실제 사기일 확률"이 82%로 준수하다는 의미이지만, Recall(0.64)이 낮다는 것은 놓치는 사기가 더 많다는 뜻이다.

금융 사기 탐지 도메인에서는 오탐지(FP, 정상 고객에게 알림이 가는 불편)보다 미탐지(FN, 실제 사기를 놓쳐 금전적 손실이 발생)의 비용이 훨씬 크다는 점을 고려하면, 이 베이스라인 모델은 아직 실무에 적용하기엔 미흡한 수준이라 평가할 수 있다.

3.4.5 소결

이번 베이스라인 평가를 통해 불균형 보정 없이 학습한 모델의 명확한 한계를 수치로 확인하였다.

- ROC-AUC(0.9582)만 보면 우수해 보이지만, 이는 불균형 데이터에서 흔히 나타나는 착시 효과에 가깝다
- 실질적 탐지 성능을 보여주는 PR-AUC 0.7391, Recall 0.64는 개선의 여지가 뚜렷하며, 특히 35건의 미탐지 사기는 실무 관점에서 심각한 리스크다

3.5 로지스틱 회귀 통계적 해석 및 오즈비(Odds Ratio) 분석

3.5.1 개요

Mann-Whitney U 검정·Cohen's d는 각 변수를 하나씩 개별적으로(단변량) 비교한 결과였다. 반면 본 절에서는 statsmodels의 Logit 모델로 전체 변수를 동시에 투입한 다변량 로지스틱 회귀를 적합하여, "다른 변수들의 영향을 통제된 상태에서" 각 변수가 사기 확률에 미치는 독립적인 효과를 정량화한다. 회귀계수(Coefficient), 오즈비(Odds Ratio, $OR = \exp(\text{계수})$), p-값, 95% 신뢰구간을 함께 산출하였으며, Train 세트(227,845건, SMOTE 미적용 원본)를 사용하였다.

오즈비 해석 기준: $OR > 1$ 이면 해당 변수가 커질수록 사기 확률이 높아지는 위험 요인(Risk Factor), $OR < 1$ 이면 사기 확률을 낮추는 **보호 요인(Protective Factor)**을 의미한다. 신뢰구간이 1을 포함하지 않아야 통계적으로 유의하다고 판단한다.

3.5.2 회귀계수 및 오즈비 산출 결과

[로지스틱 회귀 통계 해석 결과 상위 변수]			
	Coefficient	Odds_Ratio	p_value
const	-8.912181	0.000135	0.000000e+00
V4	0.796352	2.217437	2.161751e-15
V10	-0.879691	0.414911	1.086212e-13
V14	-0.563250	0.569356	1.225058e-13
V27	-0.808731	0.445423	1.660797e-09
V20	-0.511295	0.599718	3.242099e-08
V21	0.386680	1.472086	4.184572e-08
V13	-0.483538	0.616598	4.443598e-07
V8	-0.149696	0.860970	1.747330e-05
V22	0.618911	1.856906	8.311706e-05
V28	-0.245803	0.782077	1.049815e-02
Amount_Scaled	0.071243	1.073842	1.771334e-02
V5	0.178889	1.195889	2.901255e-02
V16	-0.302384	0.739054	4.884889e-02
V12	0.223148	1.250005	5.398661e-02

그림 3-9. 로지스틱 회귀계수 및 오즈비(Odds Ratio) 산출 결과

3.5.3 사기 위험을 높이는 변수 (Risk Factors, OR>1)

V4 (OR=2.22, $p<0.001$): 신뢰구간 [1.82, 2.70]로 완전히 1을 상회하며, 다른 모든 변수를 통제한 상태에서도 사기 확률을 약 2.2배 높이는 가장 강력한 위험 변수로 확인되었다.

V22 (OR=1.86, $p<0.001$), V21 (OR=1.47, $p<0.001$): 뚜렷한 양(+)의 영향력을 보이는 상위 위험 변수다.

V12 (OR=1.25), V5 (OR=1.20): p -값이 각각 0.054, 0.029로 통상적 유의수준(0.05) 경계에 있어 참고적으로만 해석한다.

Amount_Scaled (OR=1.07, $p=0.018$): 거래 금액도 통계적으로 유의하게(비록 효과크기는 작지만) 사기 확률을 높이는 요인으로 확인되었다 — 이는 3.1절의 EDA에서 확인한 "고액 거래일수록 위험이 미세하게 증가한다"는 관찰과 일치한다.

3.5.4 사기 위험을 낮추는 변수 (Protective Factors, OR<1)

V10 (OR=0.41, $p<0.001$): 오즈비가 1보다 절반 이하로, 값이 클수록 사기 확률을 가장 강력하게 낮춰주는 보호 변수다.

V27 (OR=0.45, $p<0.001$), V14 (OR=0.57, $p<0.001$), V20 (OR=0.60, $p<0.001$), V13 (OR=0.62, $p<0.001$): 모두 신뢰구간이 1을 완전히 하회하는 강력한 억제 요인이다.

V16 (OR=0.74, $p=0.049$), V28 (OR=0.78, $p=0.010$), V8 (OR=0.86, $p<0.001$): 상대적으로 약하지만 유의한 보호 효과를 보인다.

3.5.5 포레스트 플롯을 통한 시각적 확인




그림 3-10. 오즈비 포레스트 플롯(Forest Plot)

기준선(OR=1, 붉은 점선)을 기준으로 V4·V22·V21이 뚜렷하게 우측에, V10·V27·V14가 뚜렷하게 좌측에 위치해 강력한 위험군과 보호군임이 시각적으로도 명확히 드러났다. 반면 나머지 대다수 PCA 변수들은 신뢰구간이 기준선 1을 포함하거나 근접해 있어, 소수의 핵심 변수(5~6개)가 모델의 예측력을 지배하는 구조임을 확인할 수 있었다.

3.5.6 단변량(3.2절) 대비 다변량 분석 결과의 교차 검증

Cohen's d 상위 변수(V17, V14, V12, V10, V16)와 본 절의 오즈비 상위 변수(V4, V22, V21, V10, V27)를 비교하면, V10과 V14는 두 분석에서 공통적으로 강력한 판별 변수로 확인되어

결과의 일관성을 뒷받침한다.

다만 한 가지 주목할 불일치가 있다. 3.2절에서 단변량 효과크기가 가장 컸던 V17(Cohen's $d=8.32$, 1위)이, 다변량 로지스틱 회귀의 p -value 상위 15개 목록에는 나타나지 않았다. 이는 다음과 같이 해석할 수 있다.

V17이 단독으로는 정상·사기 그룹을 가장 크게 가르는 변수이지만, **다른 변수들(특히 V14, V12, V10 등)과 정보가 일부 겹쳐서** 다변량 모델에서는 그 변수들이 이미 설명하는 부분을 제외한 "고유한 추가 설명력"이 상대적으로 작게 평가되었을 가능성이 있다.

이는 **단변량 분석과 다변량 분석이 서로 다른 질문에 답하는 도구**이기 때문에 발생하는 자연스러운 현상이다 — 단변량은 "이 변수 하나만 봤을 때 얼마나 다른가"를, 다변량은 "다른 변수를 다 통제하고도 이 변수가 추가로 기여하는 바가 있는가"를 답한다.

따라서 최종 변수 중요도 판단은 어느 한 분석에만 의존하지 않고, 3.7절의 ****SHAP 분석 (비선형 앙상블 모델 기준)****까지 종합하여 세 가지 관점(단변량 효과크기·다변량 오즈비·모델 기반 중요도)을 함께 고려할 필요가 있다.

3.5.7 소결

다변량 로지스틱 회귀를 통해 V4·V22·V21을 핵심 위험 변수로, V10·V27·V14·V20·V13을 핵심 보호 변수로 통계적으로 엄밀하게($p<0.001$ 수준) 규명하였다. 단변량 분석과 비교했을 때 V10·V14는 일관되게 핵심 변수로 확인되었으나, V17처럼 단변량에서는 두드러졌지만 다변량에서는 상대적으로 약하게 나타난 변수도 있어 분석 기법에 따라 변수 중요도 순위가 달라질 수 있음을 확인하였다. 이 결과는 Feature Importance & SHAP 에서 트리 기반 앙상블 모델의 변수 중요도와 다시 한번 교차 검증된다.

3.6 앙상블 분류 모델 학습 및 성능 비교

3.6.1 개요

베이스라인(Logistic Regression, 미보정)의 한계(Recall 0.64, PR-AUC 0.7391)를 개선하기 위해, 본 절에서는 5개 분류 모델 × 3가지 불균형 처리 기법을 모두 교차 적용하는 체계적인 비교 실험을 수행하였다.

3.6.2 모델 구성

모델	주요 하이퍼파라미터
Logistic Regression	max_iter=1000
Random Forest	n_estimators=100, max_depth=10
XGBoost	n_estimators=100, max_depth=5, learning_rate=0.1
LightGBM	n_estimators=100, max_depth=5, learning_rate=0.1
Gradient Boosting(GBM)	n_estimators=100, max_depth=5, learning_rate=0.1

그림 3-11. 앙상블 모델별 주요 하이퍼파라미터 구성

3.6.3 종합 성능 비교표

[최종 5개 모델 x 기법별 비교 요약 표]

Model	Technique	ROC-AUC	PR-AUC	TP	FN	FP
Logistic Regression	Base (None)	0.958185	0.739086	63	35	14
Logistic Regression	Class Weight / Scale	0.972032	0.763887	90	8	1389
Logistic Regression	SMOTE	0.971219	0.768883	90	8	1434
Random Forest	Base (None)	0.974138	0.857018	79	19	5
Random Forest	Class Weight / Scale	0.978840	0.810753	82	16	48
Random Forest	SMOTE	0.984430	0.786490	84	14	130
XGBoost	Base (None)	0.944615	0.837342	76	22	7
XGBoost	Class Weight / Scale	0.975516	0.844478	84	14	74
XGBoost	SMOTE	0.978141	0.841086	87	11	269
LightGBM	Base (None)	0.565655	0.319060	42	56	56
LightGBM	Class Weight / Scale	0.949178	0.485829	89	9	2046
LightGBM	SMOTE	0.966623	0.781465	83	15	267
Gradient Boosting (GBM)	Base (None)	0.741778	0.589960	63	35	15
Gradient Boosting (GBM)	Class Weight / Scale	0.741778	0.589960	63	35	15
Gradient Boosting (GBM)	SMOTE	0.978922	0.709656	88	10	255

그림 3-12. 5개 모델 × 3가지 불균형 처리 기법 종합 성능 비교

3.6.4 모델별 해석

Logistic Regression: Base 대비 Class Weight, SMOTE 적용 시 FN이 35건→8건으로 크게 줄었으나, FP가 14건→1,300건대로 폭증했다. 선형 모델의 한계로 인해 불균형 보정이 오탐지를 과도하게 늘리는 트레이드오프가 뚜렷했다.

Random Forest: 세 기법 모두 안정적인 성능을 보였다. 특히 Base 상태에서도 FP가 5건에 불과해 세 조합 중 가장 "깨끗한" 예측을 보였고, SMOTE 적용 시 ROC-AUC가 전체 15개 조합 중 최고치인 0.9844를 기록했다.

XGBoost: Class Weight와 SMOTE 모두 고르게 우수했다. 특히 SMOTE 적용 시 FN이 11건으로 전체 조합 중 최저를 기록해, 사기 누락을 가장 적극적으로 방어하는 조합으로 나타났다.

LightGBM: Base 상태에서 ROC-AUC 0.5657(거의 무작위 수준)로 심각한 성능 저하를 보였다. Class Weight 적용 시 FN은 9건으로 개선되었지만 FP가 2,046건까지 폭증했으며, SMOTE 적용 후에야 비로소 ROC-AUC 0.9666·PR-AUC 0.7815로 균형 잡힌 성능에 도달했다. 불균형 보정 없이는 사실상 사용이 어려운 모델임을 확인하였다.

Gradient Boosting(GBM): Base와 Class Weight가 완전히 동일한 수치(ROC-AUC 0.7418)를 보였는데, 이는 GradientBoostingClassifier에 class_weight 파라미터 자체가 존재하지 않아 옵션이 반영되지 않았기 때문으로 판단된다. 반면 SMOTE 적용 시 ROC-AUC가 0.7418→0.9789로 극적으로 상승해, 이 모델은 알고리즘 내장 가중치 옵션이 아니라 데이터 자체를 증강하는 방식(SMOTE)에만 반응한다는 특성을 보였다.

3.6.5 최적 조합 도출

사기 누락(FN) 최소화가 최우선인 경우(놓치는 사기를 최대한 줄여야 할 때): XGBoost + SMOTE(FN 11건, ROC-AUC 0.9781) 또는 XGBoost + Class Weight(FN 14건, PR-AUC 0.8445 최고)

오탐지(FP) 비용을 최소화해야 하는 경우(불필요한 고객 알림·차단을 줄여야 할 때): Random Forest + Base(FP 단 5건, PR-AUC 0.8570)

종합 판별력(ROC-AUC) 기준 최고 성능: Random Forest + SMOTE(ROC-AUC 0.9844).

3.6.6 소결

15가지 조합을 비교한 결과, 불균형 보정 기법의 효과는 모델마다 상이하게 나타났다. LightGBM과 GBM처럼 보정 없이는 사실상 작동하지 않는 모델이 있는 반면, Random Forest는 보정 없이도 이미 우수한 성능(PR-AUC 0.8570)을 보였다.

이는 트리 기반 앙상블이라 하더라도 배깅(Random Forest)과 부스팅(XGBoost, LightGBM, GBM) 계열의 불균형 데이터 대응력이 근본적으로 다르다는 것을 시사한다.

다음 절(3.7)에서는 이 중 XGBoost(SMOTE 적용) 모델을 중심으로 어떤 변수가 실제 예측에 기여했는지 SHAP으로 해석한다.

3.7 모델 해석

3.7.1 개요

하이퍼파라미터 튜닝을 거친 XGBoost 모델을 대상으로, 모델이 실제로 어떤 변수를 근거로 사기를 판별했는지 두 가지 방법으로 해석하였다.

3.7.2 SHAP Feature Importance




그림 3-13. SHAP Feature Importance (최적화 XGBoost)

3.7.4 SHAP Beeswarm Plot




그림 3-14. SHAP Beeswarm Plot (최적화 XGBoost)

Beeswarm plot에서는 각 변수 값의 크기(색상: 파랑=낮음, 빨강=높음)가 예측에 미치는 영향의 방향(x축: SHAP 값, 양수=사기 쪽으로 밀어냄)을 함께 보여준다.

V14: 대부분의 관측치(파랑~보라색)가 SHAP 값 음수(-5~-1) 구간에 밀집해 있고, 소수의 극단적 관측치가 SHAP 값 +6~+7까지 뻗어있는 형태다.

즉 V14 값이 낮을수록 사기 쪽으로 강하게 밀어내는 경향이 우세하며, 이는 3.5절의 오즈비 분석(V14, OR=0.57 — V14가 클수록 사기 확률이 낮아짐, 즉 낮을수록 사기 확률이 높아짐)과 방향이 정확히 일치한다.

3.7.6 소결

V14를 가장 결정적인 사기 판별 변수로 지목하였으며, V4·V10·V12 등이 그 뒤를 이었다. 세 가지 통계·모델 해석 기법(효과크기, 오즈비, SHAP)을 교차검증한 결과 대체로 일관된 결론에 도달하였으나, V4의 영향 방향에 대해서는 자료 간 불일치가 발견되어 원본 시각화 재확인이 필요함을 확인하였다.

3.8 종합 비교 및 최종 결론

3.8.1 하이퍼파라미터 최적화

5가지 모델 X 3가지 불균형 처리 기법 비교를 통해 우수한 후보로 압축된 XGBoost와 Random Forest 두 모델을 대상으로, Hyperopt (TPE 알고리즘 기반 베이지안 최적화)를 이용해 PR-AUC를 목적함수로 정밀 튜닝하였다(각 모델당 10회 시행).

XGBoost 모델은 최적화 기준 (PR-AUC): 약 0.8845를 보였으며 불균형 보정을 위한 `scale_pos_weight` 와 트리 구조 파라미터가 최적 조합으로 탐색되어 매우 높은 변별력을 확보했습니다.

Random Forest 모델 최적화 기준 (PR-AUC): 약 0.8711를 보였으며 SMOTE 기법을 적용한 오버샘플링 데이터셋 기반으로 탐색되어 안정적인 앙상블 성능을 도출했습니다.

수동 그리드서치·랜덤서치 대비 효율적으로 탐색한 결과, XGBoost가 두 모델 중 더 높은 PR-AUC를 달성하여 최종 배포 모델로 선정되었다.

3.8.2 임계값(Threshold) 최적화

기본 임계값(0.5)을 그대로 쓰지 않고, F1-Score를 최대화하는 지점을 Precision-Recall 곡선에서 탐색하여 최적 임계값을 도출하였다.

```
[최적화 결과]
- 최적 Threshold : 0.9919
- 최고 F1-Score  : 0.8764
- 당시 Precision : 0.9750
- 당시 Recall    : 0.7959
```

그림 3-15. Threshold 최적화 결과

임계값을 0.9919로 극단적으로 높게 설정함으로써, 오탐지(FP)를 단 2건까지 억제하면서 도 사기 98건 중 78건(79.6%)을 정확히 잡아냈다. 이는 베이스라인(FP 14건, Recall 0.64)과

비교하면 오탐지는 86% 감소, Recall은 15% 이상 개선된 결과다.

3.8.3 전체 파이프라인 성과 요약(최종 모델)

[5개 모델 종합 성능 비교 결과 표]						
Model	ROC-AUC	PR-AUC	Recall	Precision	F1-Score	
LOGISTIC_REGRESSION	0.9720	0.7639	0.9184	0.0609	0.1141	
RANDOM_FOREST	0.9788	0.8108	0.8367	0.6308	0.7193	
XGBOOST	0.9755	0.8445	0.8571	0.5316	0.6562	
LIGHTGBM	0.9492	0.4858	0.9082	0.0417	0.0797	
GRADIENT_BOOSTING	0.9807	0.7228	0.9082	0.1085	0.1939	

그림 3-16. 최종 5개 모델 종합 성능 비교 결과

재실행에서 Gradient Boosting이 ROC-AUC 0.9807로 5개 모델 중 가장 높은 판별력을 보였다. 다만 Precision이 0.1085에 불과해, 사기로 예측한 것 중 실제 사기는 약 11%뿐이고 나머지 89%(FP 731건)는 정상 거래를 잘못 잡아낸 것이다.

즉 ROC-AUC만으로 이 모델을 최우수로 판단하면 안 되며, 불균형 데이터에서는 이번 사례처럼 PR-AUC(0.7228)·Precision을 반드시 함께 봐야 함을 다시 한번 보여주는 결과다.

3.8.4 목적별 최종 모델 추천

총 손실을 최소화하는 것이 목표라면 기본 임계값을 적용한 XGBoost가 가장 우수하다. 미탐지와 오탐지가 각각 15건과 11건으로 비교적 균형 잡혀 있어, 여섯 개 모델 중 종합적으로 가장 안정적인 조합이다.

사기 미탐지 자체를 최소화하는 것이 최우선 목표라면 Gradient Boosting(SMOTE)이나 Logistic Regression을 고려할 수 있다. 미탐지가 8~9건 수준으로 가장 적지만, 오탐지가 731건에서 1,389건까지 폭증하기 때문에 실무에 그대로 적용하기는 어렵다는 한계가 있다.

오탐지를 극도로 억제해야 하는 경우라면 임계값을 0.9919로 최적화한 XGBoost가 적합하다. 오탐지가 단 2건에 불과해 정상 고객에게 미치는 불편을 최소화할 수 있지만, 그 대

가로 미탐지가 21건까지 늘어난다는 트레이드오프를 감수해야 한다.

판별력(ROC-AUC) 자체가 목적인 초기 스크리닝 용도라면 Gradient Boosting(Class Weight)이 ROC-AUC 0.9807로 가장 높다. 다만 정밀도가 0.11에 불과해 이 모델 단독으로 최종 탐지 모델로 사용하기에는 부적합하며, 후속 필터링 단계와 함께 쓰는 것이 전제되어야 한다.

결국 어떤 모델을 최종으로 택할지는 미탐지와 오탐지 중 어느 쪽을 더 무겁게 볼 것인지에 대한 조직의 판단에 달려 있다. 그 판단 기준(미탐지와 오탐지의 상대적 비용 비율)이 달라지면 최적 모델도 함께 달라질 수 있으므로, 실제 배포 전에는 조직의 리스크 성향에 맞춰 이 비율을 재검토하고 여러 시나리오로 민감도 분석을 해보는 것을 권장한다.

4. Opinions 리뷰 데이터를 이용한 군집 분석

4.1 분석 개요

4.1.1 분석 목적 및 파이프라인

본 장에서는 제품·호텔 리뷰 문장 데이터를 대상으로 비지도학습 기반 군집분석을 수행하고, 도출된 군집(주제)이 감성(sentiment)에 어떤 영향을 미치는지 회귀분석으로 해석한다.

앞선 2장(산탄데르), 3장(신용카드 사기 검출)이 예측 정확도를 목표로 하는 지도학습 중심의 분석이었다면, 본 장은 정답 레이블이 없는 텍스트 데이터에서 잠재된 주제 구조를 스스로 발견하고, 그 구조가 감성이라는 결과 변수를 실제로 설명하는지를 검증하는 데 목적이 있다.

즉 예측 성능 자체보다 해석 가능성(interpretability)에 분석의 중심을 두었다.

전체 분석 파이프라인은 (1) 원문 로드 및 기본 정제 → (2) VADER를 이용한 문장별 감성 점수 산출 → (3) 감성어를 제외한 텍스트 정제 → (4) TF-IDF 벡터화 및 TruncatedSVD 차원 축소 → (5) 엘보우 방법을 통한 최적 군집 수(K) 결정 및 KMeans 군집화 → (6) Ridge 회귀 및 OLS 회귀를 통한 군집-감성 관계 해석 → (7) VIF·위계적 F검정·재현성 검증을 통한 통계적 엄밀성 확보의 순서로 구성된다.

4.1.2 데이터 개요 및 감성 점수 검증

분석에는 GPS 내비게이션, Kindle, iPod Nano, 넷북 2종, 호텔 3곳, 자동차 2종, Windows7 등 13개 제품·서비스에 대한 리뷰 문장 데이터를 사용하였다.

전처리 및 정제를 거친 후 최종적으로 7,084개 문장, 36개 속성(aspect)이 분석에 포함되

었다.

문장별 감성 점수는 VADER(Valence Aware Dictionary and sEntiment Reasoner)의 compound 점수(원문 기준)를 사용하였다.

점수의 타당성을 육안으로 검증한 결과, 가장 긍정적인 문장(연비·조향감·실내 만족도를 나열하며 전반적으로 만족감을 표현한 자동차 리뷰, compound=0.984)과 가장 부정적인 문장(사고 이력과 낮은 연비를 언급하며 재구매 의사를 명시적으로 부정한 자동차 리뷰, compound=-0.920)이 실제 어조와 부합하는 것으로 확인되어, 이후 분석에 VADER 점수를 신뢰하여 사용하였다.

4.2 군집 수 결정 및 주제 라벨링

4.2.1 벡터화 및 차원 축소

군집화용 텍스트는 감성어(VADER lexicon 기준 $|\text{score}| \geq 1.0$ 인 단어)를 제거한 뒤, TF-IDF(max_features=3,000, min_df=3, max_df=0.9, ngram_range=(1,2))로 벡터화하였다.

감성어를 제거한 이유는 군집이 "감성"이 아니라 "주제(무엇에 대해 말하는가)"만을 기준으로 형성되도록 하기 위함이며, 이렇게 분리해야 이후 회귀분석에서 군집이 감성에 미치는 영향을 순환논리 없이 해석할 수 있다.

2-gram을 포함한 것은 "battery life", "screen size"처럼 단어 하나로는 포착되지 않는 의미 단위를 반영하기 위함이다.

TF-IDF로 생성된 3,000차원 희소행렬은 TruncatedSVD를 통해 100차원으로 축소한 뒤 군집화에 사용하였다.

이는 고차원 공간에서 거리 기반 알고리즘(KMeans)의 성능이 저하되는 차원의 저주(curse of dimensionality)를 방지하고, 연산 효율을 높이기 위한 조치다.

TruncatedSVD는 PCA와 달리 평균 중심화 없이 희소행렬에 직접 적용할 수 있어 텍스트 데이터의 잠재의미분석(LSA)에 일반적으로 사용되는 기법이다.

4.2.2 엘보우 방법을 통한 최적 K 결정

군집 수(K)는 2~30 범위에서 KMeans의 Inertia(군집 내 분산)를 계산하고, Inertia 곡선의 시작점과 끝점을 잇는 직선에서 가장 멀리 떨어진 지점(꺾이는 지점)을 최적 K로 자동 판단하는 엘보우 방법으로 결정하였다.

아래 그림 4-1과 같이 K=12 부근에서 곡선의 기울기가 뚜렷하게 완만해지는 지점이 확인되어, 최종적으로 K=12를 채택하였다.




그림 4-1. 엘보우 방법 - 클러스터 수(K)별 Inertia

4.2.3 군집별 대표 단어 및 주제 라벨링

KMeans 군집 중심(centroid)을 TruncatedSVD의 inverse_transform을 통해 원래 TF-IDF 공간으로 되돌려, 군집별 상위 단어를 추출하였다.

12개 군집을 대표 단어 기준으로 분류한 결과, 크게 자동차(cluster_0·1·5·10), 전자제품(cluster_2·3·4), 호텔(cluster_6·7·8·9·11) 3개 대주제로 재구성됨을 확인하였다.

cluster_0(interior, battery, price, button, car, keyboard 등)은 제품 전반의 범용 어휘가 혼재된 군집이며, cluster_1(seat, transmission, leather, driver 등)은 자동차 좌석·변속기, cluster_2(video, sound, camera, quality 등)는 전자제품 음향·영상, cluster_3(battery, life,

battery life, hour 등)은 배터리 지속시간, cluster_4(screen, size, screen size, keyboard 등)는 화면 크기, cluster_5(speed, speed limit, limit, road 등)는 GPS 속도제한 안내를 주로 다룬다.

한편 cluster_6(room, small, bed, bathroom 등)은 호텔 객실 크기, cluster_7(location, hotel, tube, wharf 등)과 cluster_8(hotel location, hotel, location, staff 등)은 모두 호텔 입지를 다루지만 세부적으로는 서로 구분되는 하위 유형이며(4.5.1절 참조), cluster_9(service, room service, food, breakfast 등)는 호텔 서비스, cluster_10(mileage, gas, gas mileage, mpg 등)은 자동차 연비, cluster_11(staff, hotel, desk, front desk, concierge 등)은 호텔 직원 응대를 대표 주제로 한다.

4.3 군집-감성 관계 분석

4.3.1 군집별 평균 감성 및 제품별 분포

군집별 평균 VADER 감성 점수(그림 4-2)를 보면, cluster_8(호텔 입지, 평균 0.68)과 cluster_11(호텔 직원 응대, 평균 0.53)이 가장 높았고, cluster_1(자동차 좌석·변속기, 평균 0.03)이 가장 낮았다.




그림 4-2. 군집별 평균 감성 점수

제품×군집 히트맵(그림 4-3)에서는 동일한 "호텔 입지" 계열 군집이라도 제품별 온도차가 존재함을 확인할 수 있다.

예컨대 garmin_nuvi(GPS)는 cluster_10에서 -0.4에 가까운 강한 부정 감성을 보이는 등,

일부 셀에서는 군집의 대표 주제와 개별 제품의 실제 맥락이 어긋나는 경우도 관찰되었다.




그림 4-3. 제품 × 군집 평균 감성 히트맵

4.3.2 Ridge 회귀를 이용한 군집-감성 관계 해석

군집(원-핫 더미)에 제품·속성 더미를 통제변수로 추가하여 감성 점수를 종속변수로 하는 Ridge 회귀(alpha=1.0)를 적합하였다.

예측 성능은 RMSE=0.4072, R²=0.1528로, 이는 예측을 위한 모델이 아니라 해석을 위한 모델이라는 점에서 참고 지표로만 활용하였다.

4.3.3 감성을 높이는/낮추는 군집

Ridge 회귀계수(그림 4-4) 기준으로, 감성을 가장 높이는 군집은 cluster_8(호텔 입지, +0.21), cluster_11(호텔 직원, +0.19), cluster_3(배터리 지속시간, +0.16) 순이었다.

반대로 감성을 가장 낮추는 군집은 cluster_1(자동차 좌석·변속기, -0.41)이 압도적이었고, cluster_0(-0.08)과 cluster_10(연비, -0.08)이 뒤를 이었다.

cluster_1의 계수가 다른 군집보다 2배 이상 큰 음(-)의 값을 보인다는 점은, 좌석·변속기 관련 리뷰가 전반적으로 불만이 집중되는 영역임을 시사한다.




그림 4-4. 군집별 감성 영향력 (Ridge 회귀계수)

4.4 통계적 검증

4.4.1 OLS 회귀 및 유의성 검증

Ridge는 정규화 회귀 특성상 p-value를 제공하지 않으므로, 통계적 유의성 검정을 위해 statsmodels의 OLS(이분산-강건표준오차 HC3 적용)를 별도로 적합하였다.

그 결과 cluster_8(coef=0.311, $p<0.001$), cluster_11(coef=0.308, $p<0.001$), cluster_3(coef=0.234, $p<0.001$), cluster_9(coef=0.130, $p<0.001$), cluster_7(coef=0.122, $p<0.001$), cluster_1(coef=-0.297, $p<0.001$) 등 6개 군집이 1% 유의수준에서 유의하였다. 반면 cluster_5, cluster_6, cluster_4, cluster_10은 유의하지 않았고($p>0.1$), cluster_2는 $p=0.052$ 로 경계선상에 있었다.

즉 12개 군집 중 절반 정도만이 통계적으로 뚜렷한 설명력을 가진다. 12개 군집에 대한 개별 검정이므로 다중검정에 따른 1종 오류 팽창 가능성을 고려할 필요가 있다.

다만 Bonferroni 보정 기준($\alpha=0.05/12\approx 0.0042$)을 적용하더라도 $p<0.001$ 수준인 6개 군집(cluster_8·11·3·9·7·1)의 유의성은 그대로 유지되며, 검정 개수가 적어 보정으로 인한 판단 번복 위험은 낮다.

군집	대표 단어	계수(coef)	표준오차	t값	p-value	유의성
cluster_8	hotel location, hotel, location	0.3115	0.0450	6.914	4.70e-12	***
cluster_11	staff, hotel, hotel staff	0.3084	0.0379	8.146	3.76e-16	***
cluster_3	battery, life, battery life	0.2337	0.0316	7.399	1.37e-13	***
cluster_9	service, room service, room	0.1303	0.0359	3.626	2.88e-04	***
cluster_7	location, hotel, tube	0.1223	0.0367	3.336	8.51e-04	***
cluster_2	video, sound, camera	0.1217	0.0627	1.941	0.0522	.
cluster_5	speed, speed limit, limit	0.0408	0.0585	0.697	0.4857	
cluster_6	room, small, bed	0.0372	0.0294	1.263	0.2066	
cluster_4	screen, size, screen size	0.0343	0.0378	0.908	0.3641	
cluster_10	mileage, gas, gas mileage	-0.0162	0.0529	-0.306	0.7597	
cluster_1	seat, transmission, leather	-0.2970	0.0620	-4.793	1.64e-06	***

표 4-1. 군집별 OLS 회귀계수 및 유의성 검증 결과 (1차, VIF 정제 전)

4.4.2 다중공선성 점검(VIF) 및 단계적 제거

1차 VIF 진단 결과,

product_mileage_toyota_camry_2007.txt·product_asus_netbook_1005ha.txt는 완전 다중공선성($VIF=inf$)을 보였고,

product_bestwestern_hotel_sfo.txt(28.74)·product_honda_accord_2008.txt(27.12) 등 통제변수 다수가 기준치($VIF \geq 10$)를 상회하였다.

이는 특정 속성(aspect)이 사실상 단일 제품에서만 등장하여(예: mileage 속성은 camry에만 존재) 제품 더미와 속성 더미가 사실상 동일한 정보를 담고 있는 구조적 특성에서 비롯된 것으로 판단된다.

변수명	VIF
product_mileage_toyota_camry_2007.txt	inf
aspect_gas	inf
aspect_size	inf
product_asus_netbook_1005ha.txt	4.20e+09
product_bestwestern_hotel_sfo.txt	28.737
product_honda_accord_2008.txt	27.118
product_toyota_camry_2007.txt	26.103
product_holiday_inn_london.txt	24.955
aspect_location	16.767
aspect_comfort	15.485
aspect_staff	14.337
aspect_service	12.770
aspect_room	11.962
aspect_transmission	11.770
aspect_interior	11.442

표 4-3. 다중공선성(VIF) 상위 15개 변수 (1차)

군집(cluster_*) 변수는 분석의 핵심 관심 변수이므로 제거 대상에서 제외하고, VIF가 가장 높은 통제변수부터 한 번에 하나씩 제거하며 재계산하는 단계적 제거(stepwise elimination)를 반복 적용하였다.

그 결과 4개 변수가 제거되었고, 정제 후에는 $VIF \geq 10$ 인 변수가 0개로 해소되었다.

군집 변수만의 VIF는 최대 cluster_2의 6.48로 모두 안정적인(<10) 수준을 유지하였다.

변수명	VIF
product_windows7.txt	8.576
aspect_video	7.745
aspect_speed	7.523
product_ipod_nano_8gb.txt	6.493
cluster_2	6.482
aspect_location	6.237
product_garmin_nuvi_255W_gps.txt	5.684
product_netbook_1005ha.txt	5.433
aspect_screen	5.399
cluster_7	5.223
cluster_6	4.963
aspect_staff	4.821
aspect_service	4.804
cluster_11	4.725
aspect_room	4.469

표 4-4. 다중공선성(VIF) 상위 15개 변수 (정제 후)

참고로, VIF 정제 후 축소된 설계행렬로 OLS를 재적합한 결과(표 4-2)는 정제 전(표 4-1)과 군집별 계수의 부호·유의성 패턴이 거의 동일하게 유지되어, 다중공선성 정제가 핵심 해석 결과에 미치는 영향은 크지 않은 것으로 확인되었다.

군집	대표 단어	계수(coef)	표준오차	t값	p-value	유의성
cluster_8	hotel location, hotel, location	0.3268	0.0447	7.317	2.54e-13	***
cluster_11	staff, hotel, hotel staff	0.3179	0.0378	8.419	3.78e-17	***
cluster_3	battery, life, battery life	0.2346	0.0316	7.429	1.10e-13	***
cluster_9	service, room service, room	0.1385	0.0359	3.861	1.13e-04	***
cluster_7	location, hotel, tube	0.1367	0.0364	3.750	1.77e-04	***
cluster_2	video, sound, camera	0.1207	0.0628	1.922	0.0546	.
cluster_6	room, small, bed	0.0461	0.0293	1.575	0.1153	
cluster_5	speed, speed limit, limit	0.0391	0.0581	0.673	0.5011	
cluster_4	screen, size, screen size	0.0337	0.0378	0.892	0.3723	
cluster_10	mileage, gas, gas mileage	-0.0146	0.0529	-0.277	0.7817	
cluster_1	seat, transmission, leather	-0.2956	0.0618	-4.781	1.74e-06	***

표 4-2. 군집별 OLS 회귀계수 및 유의성 검정 결과 (VIF 정제 후)

4.4.3 위계적 회귀 F검정

군집이라는 요인 블록이 통계적으로 유의한 설명력을 추가하는지 확인하기 위해, 통제변수 (제품·속성)만 포함한 축소모형과 군집 더미를 추가한 완전모형을 비교하는 위계적 회귀 F 검정을 실시하였다.

축소모형 $R^2=0.1177$, 완전모형 $R^2=0.1416$ 으로 $\Delta R^2=0.0239$ 였으며, $F=17.805(df=11, p=1.818e-35)$ 로 군집 블록은 1% 유의수준에서 감성에 대한 설명력을 유의하게 추가하는 것으로 나타났다.

4.4.4 군집 안정성 검증(실루엣 점수 및 ARI 재현성)

군집의 기하학적 분리도를 나타내는 실루엣 점수는 0.0641로 낮게 나타났다.

이는 일반적 기준(0.3 이상 양호)에 비해 낮은 수준이지만, 자연어 리뷰 문장은 주제 경계가 원래 뚜렷하게 갈라지지 않는 경우가 많아 텍스트 군집화에서 종종 관찰되는 현상이다.

실제로 4.5절에서 다루는 것처럼, 본 데이터의 호텔 관련 군집(7·8·9·11) 4개가 서로 인접한 주제를 다루고 있어 실루엣 점수를 낮추는 주요 원인으로 작용한 것으로 판단된다.

한편 KMeans의 초기값(random_state) 의존성을 점검하기 위해 seed를 10회 변경하며 재 군집화한 뒤, 최초 결과(seed=42)와의 일치도를 ARI(Adjusted Rand Index)로 측정하였다.

평균 ARI=0.5859(표준편차 0.1350, 최소 0.3204, 최대 0.8014)로, 군집의 전반적인 구조는 재현되지만 경계에 위치한 일부 문장은 seed에 따라 유동적으로 배정될 수 있는 중간 수준의 안정성을 보였다.

정리하면, 군집의 기하학적 분리는 완벽하지 않지만(실루엣 0.06, ARI 중간 수준), 통계적으로는 감성을 유의하게 설명한다(위계적 F검정 $p<0.001$)는 이중적 결과가 확인되었다.

이는 군집의 기하학적 응집도와 통계적 설명력이 서로 다른 성질의 지표이며, 특히 텍스트 데이터에서는 이 둘이 반드시 일치하지 않을 수 있음을 보여준다.

다만 회귀분석의 표준적 가정 중 오차항의 독립성은 완전히 충족되지 않을 가능성이 있다. 동일 제품에서 추출된 문장들은 같은 리뷰어·맥락을 공유하므로 서로 독립적이지 않을 수 있으며, 이를 무시할 경우 표준오차가 과소추정되어 유의성이 실제보다 과대평가될 위험이 있다.

등분산성은 HC3 강건표준오차로, 다중공선성은 VIF 기반 단계적 제거로 보정하였고, 정규성은 표본 크기(N=7,084)가 충분히 커 중심극한정리에 따라 검정 결과에 미치는 영향이 제한적이나, 독립성 문제는 후속 분석에서 제품 단위의 군집표준오차(clustered standard error)를 적용해 보완할 필요가 있다.

4.5 군집 해석 시 주의사항

4.5.1 유사 군집의 분리 — cluster_7 vs cluster_8

cluster_7과 cluster_8은 대표 단어(location, hotel 등)가 거의 동일하여 표면적으로는 같은 주제로 보이지만, 실제 문장을 대조해 보면 뚜렷한 차이가 확인된다.

cluster_8(86개 문장, 평균 감성 0.68)은 "great hotel in a lovely location", "a fantastic hotel and a great location"처럼 짧고 단정적인 극찬형 문장 위주로 구성된 반면, cluster_7(627개 문장, 평균 감성 0.49)은 입지를 언급하면서도 가격·주변 환경·관광지 접근성 등 다른 요소를 함께 서술하거나 조건부·양보 표현이 섞인 더 길고 복합적인 문장이 많았다.

즉 두 군집은 같은 "입지"라는 주제 안에서도 서술의 단순성과 감성 강도가 체계적으로 다른, 실질적으로 구분되는 하위 유형을 포착한 것으로 해석할 수 있다.

4.5.2 혼합형 군집의 해석 제한 — cluster_0

cluster_0은 2,628개 문장(전체의 37.1%)으로 다른 군집 대비 압도적으로 크며, 13개 제품 전부와 36개 속성 전부에 걸쳐 나타난다.

대표 단어도 interior, battery, price, button, car, keyboard 등 서로 다른 제품군의 어휘가 뒤섞여 있어 하나의 일관된 주제로 보기 어렵다.

실제 문장을 보면 가격, GPS 정확도, 자동차 성능 등 서로 무관한 짧고 일반적인 표현이 제품과 무관하게 뒤섞여 있음을 확인할 수 있다.

이는 TF-IDF+SVD+KMeans 파이프라인이 뚜렷한 어휘 패턴을 찾지 못한 문장들을 하나의 잔여(catch-all) 군집으로 묶어버리는 전형적인 한계를 보여준다.

Ridge/OLS 회귀에서도 cluster_0의 계수(-0.08)는 유의하지 않거나(OLS 기준 $p=0.36$) 약한 음의 값에 그쳤는데, 이는 cluster_0이 실제로 감성에 부정적인 영향을 미치는 주제라기보다 특정 주제로 분류되지 않는 잡다한 문장들의 집합이기 때문일 가능성이 크다.

따라서 cluster_0의 회귀계수는 다른 11개 군집과 같은 층위에서 주제의 영향력으로 해석하기보다, 별도의 잔여 범주로 취급하여 해석에 신중을 기해야 한다.

4.6 종합 시각화 및 해석

4.6.1 체르노프 페이스를 통한 종합 시각화

12개 군집의 특성을 한눈에 비교하기 위해 체르노프 페이스(Chernoff Faces)를 활용하였다(그림 4-5).

각 얼굴의 크기는 해당 군집의 문장 수, 눈 크기는 감성 점수의 표준편차(군집 내 의견 편차), 눈썹 각도는 Ridge 회귀계수, 입 모양은 평균 감성, 얼굴 색상은 회귀계수의 부호(초록=양, 빨강=음, 회색=계수가 0에 가까워 유의미하지 않은 경우)를 각각 매핑하였다.




그림 4-5. 군집별 체르노프 페이스

이 시각화를 통해 cluster_0이 가장 큰 얼굴(최대 문장 수)이면서도 표정이 뚜렷하지 않은 붉은 계열이라는 점, cluster_8·cluster_11이 뚜렷한 미소(높은 평균 감성)와 초록색(양의 계수)을 동시에 보인다는 점, cluster_6만 유일하게 회색(계수가 -0.03으로 0에 가까움)으로 표시되어 통계적으로도 유의하지 않았던 결과(4.4.1절)와 일치한다는 점을 시각적으로 재확인할 수 있다.

4.6.2 종합 해석

본 장의 분석을 종합하면 다음과 같다.

첫째, TF-IDF + SVD + KMeans 파이프라인은 리뷰 문장을 자동차·전자제품·호텔이라는 3개 대주제, 12개 세부 군집으로 성공적으로 구조화하였다.

둘째, 이렇게 도출된 군집은 위계적 회귀 F검정($p < 0.001$)을 통해 감성 점수에 대해 통계적으로 유의한 설명력을 가지는 것으로 확인되었으며, 특히 호텔 입지(cluster_8)·호텔 직원(cluster_11)·배터리 지속시간(cluster_3)은 감성을 유의하게 높이는 반면, 자동차 좌석·변속기(cluster_1)는 감성을 유의하게 낮추는 핵심 주제로 나타났다.

셋째, 실루엣 점수(0.06)로 대표되는 기하학적 분리도는 낮았으나, 이는 통계적 설명력과는 별개의 지표이며 자연어 텍스트의 본질적 특성(주제 간 의미 중첩)에서 기인한 것으로 해석하는 것이 타당하다.

넷째, cluster_0과 같은 대규모 혼합형 군집의 존재는 비지도학습 기반 텍스트 군집화가 갖는 구조적 한계이며, 후속 분석에서는 이러한 잔여 군집을 별도로 표시하거나 분석 대상에서 제외하는 방안을 고려할 필요가 있다.

5. Mercari 상품 가격 분석 및 예측

5.1 문제 정의

5.1.1 프로젝트 배경 및 비즈니스 문제

온라인 중고거래 플랫폼에서는 상품의 특성과 시장 상황에 따라 적절한 판매 가격을 설정하는 것이 중요하다.

가격이 지나치게 높으면 판매 가능성이 낮아지고, 반대로 지나치게 낮으면 상품의 잠재적 가치를 충분히 반영하지 못한다.

본 장에서는 Mercari 상품 데이터를 활용하여 상품의 다양한 특성과 가격 간의 관계를 분석하고, 상품 정보를 기반으로 가격을 예측하는 모델을 구축한다.

단순한 가격 예측에 그치지 않고 통계적 분석과 머신러닝을 함께 활용하여 가격 결정 요인을 해석하고 예측 모델의 성능을 비교하는 것을 목표로 한다.

Mercari 상품 등록 과정에서 상품의 특성을 바탕으로 적절한 가격 수준을 추정할 수 있다면 판매자의 가격 설정을 지원하고 플랫폼의 상품 가격 분석에도 활용할 수 있다.

이에 따라 상품의 어떤 특성이 판매 가격에 영향을 미치는지, 상품 특성만으로 적정 가격을 예측할 수 있는지, 텍스트 정보(상품명·상품 설명)가 가격 예측 성능 향상에 기여하는지를 핵심 비즈니스 질문으로 설정하였다.

5.1.2 통계적 질문 및 머신러닝 질문

통계적 분석 측면에서는 상품 상태에 따라 가격에 유의한 차이가 존재하는지, 카테고리 및 브랜드가 가격에 유의한 영향을 미치는지, 여러 변수를 동시에 통제했을 때 각 변수의 영향

력이 어떻게 달라지는지, 그리고 다중회귀모형의 통계적 가정이 적절히 충족되는지를 검증하고자 하였다.

이를 위해 탐색적 데이터 분석 이후 다중회귀분석을 수행하고 회귀계수·유의확률·결정계수·다중공선성(VIF)을 검토한다.

머신러닝 측면에서는 상품 특성만으로 가격을 어느 정도 정확하게 예측할 수 있는지, 선형 회귀모델과 비선형 모델의 예측 성능에 차이가 있는지, Ridge와 같은 정규화 회귀모델이 일반 선형회귀보다 안정적인지, 상품명·상품 설명과 같은 텍스트 정보가 예측 성능을 향상시키는지, 그리고 머신러닝 모델이 중요하게 판단하는 변수가 통계적 회귀분석의 유의변수와 어떻게 다른지를 확인하고자 하였다.

5.1.3 분석 프로세스

데이터 이해 → 데이터 품질 검증 → 탐색적 데이터 분석(EDA) → 통계적 분석(다중회귀) → Feature Engineering → 머신러닝 모델링 → 모델 평가 및 비교 → 결론 및 개선 방안의 순서로 분석을 진행하였다.

데이터 규모는 148만 건 이상으로 대규모이며, 통계적 추론 단계에서는 계산 부담을 고려하여 20만 건의 무작위 표본을 사용하고, 머신러닝 모델링 단계에서는 전체 데이터를 사용하였다.

5.2 데이터 이해 및 탐색적 데이터 분석

5.2.1 데이터 개요 및 품질 검증

분석 데이터는 총 1,482,535개의 상품과 8개 변수(train_id, name, item_condition_id, category_name, brand_name, price, shipping, item_description)로 구성된다.

price를 목표변수로 설정하고, train_id는 식별자이므로 모델링에서 제외하였다.

name과 item_description은 텍스트 변수로, 기본 회귀모델에서는 별도 처리하고 이후 Feature Engineering 단계에서 텍스트 정보의 활용 방안을 검토하였다.

결측치를 확인한 결과 brand_name에서 632,682건(42.68%)의 결측치가 발생하여 가장 높은 결측률을 보였으며, category_name은 6,327건(0.43%), item_description은 6건(0.0004%)으로 매우 낮은 수준이었다.

brand_name은 결측 행을 단순 제거할 경우 상당한 표본 손실이 발생하므로, 결측 자체가 상품의 특성(무브랜드 상품)을 반영할 가능성을 고려하여 이후 EDA에서 가격과의 관계를 확인한 후 처리 방법을 결정하였다.

중복 데이터를 검토한 결과 완전히 동일한 행과 train_id 중복 모두 0건으로 확인되어 중복으로 인한 분석 편향 가능성은 낮았다.

price 변수는 최솟값이 0으로 나타났으며, $price \leq 0$ 인 관측치가 874건(약 0.06%) 존재하였다.

이는 모두 price = 0이었고 음수 가격은 없었다.

상품의 판매가격이라는 변수 특성상 0원은 유효한 판매가격으로 보기 어려워 비정상값으로 판단하였고, 원본 데이터는 유지하되 전처리 단계에서 제외하기로 하였다.

5.2.2 Target 변수(가격) 분포 및 로그 변환

price의 기초통계량을 확인한 결과 평균은 26.74, 중앙값은 17.00으로 평균이 중앙값보다 높았으며, 최댓값은 2,009로 나타나 일부 고가 상품이 전체 평균을 끌어올리고 있음을 시사하였다.

가격 분포를 시각화한 결과(그림 5-1) 대부분의 상품이 낮은 가격대에 집중되어 있고 고가 상품이 오른쪽으로 길게 분포하는 우측 왜도가 뚜렷하게 관찰되었다.




그림 5-1. Mercari 상품 가격(원본, price) 분포

왜도(skewness)를 계산한 결과 원본 price는 11.3937로 매우 큰 양의 값을 보였다.

이러한 극단적인 비대칭성은 선형 회귀모형의 적합과 잔차 구조에 부정적인 영향을 줄 수 있으므로, $\log_{10}(\text{price})$ 변환을 적용하였다.

변환 결과(그림 5-2) 왜도는 0.6991로 크게 감소하였으며(약 10.69포인트 감소), 히스토그램에서도 극단적인 오른쪽 꼬리가 압축되고 보다 대칭적인 분포에 가까워지는 것을 확인하였다.

이에 따라 이후 통계적 회귀분석 및 머신러닝 모델링에서는 $\log_price = \log(1 + price)$ 를 목표변수로 사용하였다.




그림 5-2. 로그 변환 가격(log1p(price)) 분포

5.2.3 이상치 탐색(IQR 기준)

가격 변수의 극단값을 정량적으로 확인하기 위해 IQR 기준을 적용하였다.

Q1은 10, Q3는 29로 IQR은 19였으며, 상한 기준은 57.5로 계산되었다.

이 기준을 초과하는 상품은 119,352건(8.05%)으로, 해당 집단의 평균 가격은 112.88, 중앙값은 84.00이었다(그림 5-3).

다만 상위 가격 상품의 상품명·카테고리·브랜드를 실제로 검토한 결과 Chanel, Louis Vuitton, Celine 등의 명품과 Apple iPad Pro, 고가 주얼리 등 정상적인 고가 상품이 다수 포함되어 있었다.




그림 5-3. IQR 기준(57.5 초과) 고가 상품 분포

따라서 IQR 기준을 이상치 "제거" 기준이 아니라 가격 분포의 극단값을 탐색하는 기준으로만 활용하였다.

통계적 이상치 후보(고가 상품)는 자연스러운 가격 변동으로 판단하여 유지하고, 그 영향력은 앞서 확인한 로그 변환을 통해 완화하는 방향을 택하였다

반면 price = 0인 874건은 유효한 판매가격으로 볼 수 없으므로 별도의 비정상값으로 구분하여 전처리 단계에서 제외하였다.

5.2.4 설명변수 분포 및 가격과의 관계

item_condition_id는 상태 1이 640,549건(43.20%)으로 가장 많았고 상태 2(25.32%), 상태 3(29.15%) 순으로, 상태 1~3에 전체의 약 97.7%가 집중되어 있었다(그림 5-4).

shipping은 판매자 부담이 819,435건(55.27%), 구매자 부담이 663,100건(44.73%)으로 비교적 균형 있게 분포하였다(그림 5-5).

category_name은 1,287개(그림 5-6은 상위 20개), brand_name은 4,809개(그림 5-7은

상위 20개)의 고유값을 가지는 고카디널리티 변수였다.




그림 5-4. 상품 상태(item_condition_id)별 분포




그림 5-5. 배송비 부담 주체(shipping)별 분포




그림 5-6. 상위 20개 카테고리별 상품 분포




그림 5-7. 상위 20개 브랜드별 상품 분포

가격과의 관계를 확인한 결과, 상품 상태별 가격 차이는 크지 않았다(그림 5-8, 중앙값 15~19 범위).

반면 배송비 부담 주체는 뚜렷한 차이를 보였는데(그림 5-9, 5-10), 판매자 부담 상품의 중앙값(20.00)이 구매자 부담 상품의 중앙값(14.00)보다 약 42.9% 높았다.




그림 5-8. 상품 상태별 가격 증양값




그림 5-9. 배송비 부담 주체별 가격 증양값




그림 5-10. 배송비 부담 주체별 로그 가격 분포(Boxplot)

카테고리별로는(그림 5-11, 5-12) Women/Women's Handbags/Shoulder Bag의 가격 중앙값이 36.00으로 가장 높았고 일부 저가 카테고리는 중앙값이 10 수준에 그쳐, 카테고리에 따라 상품의 일반적인 가격대가 상당히 차이를 확인하였다.

브랜드별로도(그림 5-13, 5-14) Michael Kors(중앙값 49.00), Lululemon(39.00) 등 고가 브랜드와 Old Navy(11.00), FOREVER 21(12.00) 등 저가 브랜드 간 차이가 뚜렷하였다.

다만 이러한 단변량 관계는 다른 변수의 영향이 통제되지 않은 결과이므로, 각 변수의 순수한 영향력은 다음 절의 다중회귀분석에서 확인한다.




그림 5-11. 상위 20개 카테고리별 가격 중앙값




그림 5-12. 상위 20개 카테고리별 로그 가격 분포(Boxplot)




그림 5-13. 상위 20개 브랜드별 가격 중앙값




그림 5-14. 상위 20개 브랜드별 로그 가격 분포(Boxplot)

5.2.5 다중회귀분석을 통한 통계적 검증

가격에 영향을 미치는 요인을 통계적으로 검증하기 위해 $\log_price$ 를 종속변수로 하는 OLS(Ordinary Least Squares) 다중회귀분석을 수행하였다.

전체 데이터는 약 148만 건으로 규모가 매우 크고 범주형 변수의 더미화에 따른 계산 부담이 크므로, 통계적 추론을 위한 OLS 분석에서는 20만 건의 무작위 표본을 사용하였다.

분석 변수는 상품 상태, 배송비 부담 여부, 카테고리(대·중·소분류), 상품명·상품 설명의 길이 등 해석 가능한 변수로 구성하였고, 고차원 텍스트 변수인 TF-IDF 특성은 통계적 해석보다 머신러닝 예측에 적합하므로 본 절의 회귀분석에서는 제외하였다.

One-Hot Encoding을 적용한 882개의 설명변수로 Full OLS 모델을 적합한 결과, $R^2=0.2912$, Adjusted $R^2=0.2881$, $RMSE=0.6265$ (로그 스케일), $AIC=382,317.01$ 로 나타났다. F-statistic은 93.29이고 F검정의 p-value가 0.001 미만으로 모형 전체는 통계적으로 유의하였다.

즉 상품 상태·배송비 부담·카테고리·텍스트 길이 등의 설명변수와 가격 사이에는 통계적으로 유의한 관계가 존재한다고 판단할 수 있다.

882개 변수 각각의 개별 유의성을 $\alpha=0.05$ 기준으로 검정한 결과, 348개(39.46%)가 유의하였고 534개(60.54%)는 유의하지 않았다.

다만 이 단계는 882개의 개별 가설을 $\alpha=0.05$ 기준으로 동시에 검정한 것이므로, 2장·3장에서 변수 선택 시 적용한 것과 마찬가지로 다중검정에 따른 1종 오류 팽창 문제를 고려해야 한다.

모든 귀무가설이 참이라고 가정해도 순전히 우연에 의해 약 44개(882×0.05) 변수가 유의한 것으로 나타날 수 있다.

따라서 이 단계의 348개 변수 선정은 확증적(confirmatory) 가설검정이 아니라, 이후 VIF 진단과 재검정을 거쳐 최종 변수 집합을 좁혀가는 탐색적(exploratory) 변수 스크리닝 절차로 해석하는 것이 타당하다.

다만 이후 확정되는 핵심 변수(shipping, item_condition_id, category_1 대분류 더미)는 모두 $p < 0.001$ 수준으로, Bonferroni 보정 기준($\alpha/882 \approx 5.7 \times 10^{-5}$)을 적용하더라도 여전히 유의하여 이 결론들의 견고성은 유지된다.

유의한 348개 변수만으로 모델을 재적합하기에 앞서 다중공선성을 점검하기 위해 VIF(분산팽창요인)를 계산한 결과, VIF가 10을 초과하는 변수가 8개 확인되었다(표 5-1).

가장 높은 변수는 category_2_Hair Care로 $VIF=38.54$ 였으며, 이들 8개 변수를 제거하여 340개 변수로 축소하였다.

변수명	VIF
category_2_Hair Care	38.540
category_3_Two Button	16.547
category_2_Toy	14.336
category_2_Blazers & Sport Coats	14.004
category_3_Styling Products	13.527
category_3_Action Figure	11.551
category_2_Antique	10.886
category_3_Shampoo & Conditioner Sets	10.012

표 5-1. 다중공선성(VIF) 상위 8개 변수 (1차, VIF>10 기준 제거 대상)

VIF 기준으로 정제한 340개 변수로 OLS를 재적합한 결과, 다중공선성 문제가 해소되면서 일부 변수의 유의성이 달라져 40개 변수가 새롭게 유의하지 않은 것으로 나타났다(유의 300개, 비유의 40개).

이에 따라 유의한 300개 변수만으로 다시 OLS를 재적합하였고($R^2=0.2677$, Adj. $R^2=0.2666$, RMSE=0.6369), 재검증한 VIF에서는 10을 초과하는 변수가 0개로 완전히 해소되었음을 확인하였다.

이후 회귀계수 크기 상위 변수 중 표본 편중이 의심되는 3개 범주(category_2_Dolls and Miniatures, category_3_Animals, category_3_Favors)를 추가로 제외하여, 최종적으로 297개 설명변수로 구성된 모델을 확정하였다.

구분	Full OLS	VIF 정제(1차)	최종 모델
설명변수 수	882개	340개	297개
R^2	0.2912	0.2683	0.2677
Adjusted R^2	0.2881	0.2673	0.2666
RMSE (log 스케일)	0.6265	0.6367	0.6369
AIC	382,317.01	—	387,690.50
VIF > 10 변수 수	(미확인)	8개→0개	0개

표 5-2. OLS 모델 단계별 비교 (Full → VIF 정제 → 최종 297개 변수)

최종 297개 변수 모델의 R^2 는 0.2677로, log_price 변동의 약 26.8%를 모델이 설명한다.

Adjusted R^2 (0.2666)가 R^2 와 큰 차이를 보이지 않아 다수의 변수 사용에 따른 설명력 과대 평가는 크지 않은 것으로 판단된다.

RMSE는 0.6369(로그 스케일)였다.

회귀계수를 검토한 결과 shipping의 계수는 $-0.2767(p<0.001)$ 로, 다른 변수를 통제한 상태에서 구매자가 배송비를 부담하는 상품일수록 가격이 유의하게 낮음을 확인하였다.

item_condition_id의 계수는 $-0.0975(p<0.001)$ 로 상품 상태를 나타내는 숫자가 클수록(상태가 나쁠수록) 가격이 낮아지는 방향으로 유의하였다.

category_1_Electronics(+0.8451), category_1_Men(+0.3764), category_1_Women(+0.2928) 등 대분류 카테고리 더미 역시 강하게 유의하여, 카테고리가 가격을 설명하는 핵심 변수임을 재확인하였다.

5.2.6 회귀분석 가정 검토

최종 모델의 통계적 타당성을 확인하기 위해 회귀분석의 표준 가정 네 가지를 순차적으로 검토하였다.

가정	검정 방법	결과값	판정
선형성	Ramsey RESET 검정	$F=179.70, p=5.87 \times 10^{-4}$	위반 (비선형성 신호 확인)
독립성	Durbin-Watson 통계량	DW=1.998	만족 (2에 근접)
등분산성	잔차 vs 적합값·관측순서 산점도	육안 검토	대체로 만족
정규성	Q-Q Plot, 잔차 히스토그램	육안 검토	대체로 만족

표 5-3. 최종 OLS 모델의 회귀분석 가정 검토 결과

독립성은 Durbin-Watson 통계량이 1.998로 2에 매우 근접하여 잔차의 자기상관 문제가 없는 것으로 판단하였다.

등분산성은 잔차 대 적합값 산점도(그림 5-15)에서 특별한 패턴이나 깔때기 형태가 관찰되지 않아 대체로 만족하는 것으로 판단하였다.




그림 5-15. 잔차 대 예측값(Fitted Values) 산점도

정규성은 잔차 히스토그램(그림 5-16)이 대체로 종모양을 보이고 Q-Q Plot에서도 대부분의 점이 45도 기준선에 가깝게 위치하여 만족하는 것으로 판단하였다.




그림 5-16. 회귀모형 잔차 분포

다만 선형성은 Ramsey RESET 검정 결과($F=179.70$, $p<0.001$)에서 귀무가설이 기각되어 비선형성 신호가 확인되었다.

이는 One-Hot Encoding된 범주형 더미변수가 절대다수를 차지하는 모델 특성상, 설명변수와 $\log_price$ 사이에 선형모형이 포착하지 못하는 비선형적 관계 또는 변수 간 상호작용이 존재할 가능성을 시사한다.

이러한 비선형성은 이후 5.4절의 트리 기반 머신러닝 모델(LightGBM, XGBoost, GBM, Random Forest)이 선형 모델 대비 갖는 이점과 연결되는 지점으로, OLS의 선형성 가정 위반은 통계적 회귀분석의 한계인 동시에 비선형 모델을 함께 검토해야 하는 근거로 해석하였다.

5.3 데이터 전처리 및 텍스트 정제

5.3.1 불필요 변수 제거 및 비정상값·결측치 처리

식별자인 train_id는 가격을 설명하는 정보를 포함하지 않으므로 제거하였다.

EDA에서 확인한 $\text{price} \leq 0$ 인 874건은 정상적인 판매가격으로 볼 수 없어 $\text{price} > 0$ 조건으로 제외하였고, 그 결과 전체 1,482,535건에서 1,481,661건으로 축소되었다(최소 가격 0→3, 평균 26.75, 중앙값 17.00).

brand_name(결측률 42.68%)과 category_name(0.43%)은 결측 자체가 상품의 특성일 수 있다고 판단하여 "Unknown" 범주로 대체하였다

item_description(결측률 0.0004%)은 텍스트 분석 과정에서 빈 문자열로 처리해도 무리가 없어 공백("")으로 대체하였다.

처리 후 모든 변수에서 결측값이 존재하지 않음을 확인하였다.

5.3.2 카테고리 계층 분리 및 브랜드 희소성 처리

category_name은 "/"를 기준으로 계층적 분류 정보를 포함하므로, 이를 대분류(category_1)·중분류(category_2)·소분류(category_3)로 분리하였다.

이를 통해 상품의 계층적 특성을 유지하면서 각 수준의 카테고리가 가격에 미치는 영향을 독립적으로 분석할 수 있도록 하였다.

brand_name은 4,808개의 고유 브랜드로 구성되어 있었고 빈도 편차가 매우 컸다.

중앙값은 4개 상품에 불과한 반면 최다 브랜드는 632,336개 상품을 보유하였으며, 상품이

1개뿐인 브랜드도 1,241개에 달해 강한 희소성이 확인되었다.

이러한 희소 브랜드를 모두 개별 범주로 유지하면 인코딩 차원이 크게 증가하고 과적합 위험이 커지므로, 상품 수 10개 미만인 브랜드를 "Other" 범주로 통합하여 범주 수를 축소하였다.

5.3.3 텍스트 파생변수 및 TF-IDF 벡터화

name과 item_description은 가격 예측에 유용한 정보를 포함할 수 있으므로 제거하지 않고, 우선 텍스트의 구조적 특성을 수치화한 파생변수(name_length, description_length)를 생성하였다.

상품명의 평균 길이는 25.79자였으며, 상품 설명의 평균 길이는 145.71자(표준편차 174.45, 최대 1,046자)로 상품별 편차가 컸다.

원문 텍스트는 TF-IDF(Term Frequency-Inverse Document Frequency)로 수치화하였다.

특정 상품에서 자주 등장하면서 전체 상품에서는 상대적으로 드문 단어에 높은 가중치를 부여하기 위해 TF-IDF 방식을 채택하였고, 단일 단어(unigram)뿐 아니라 연속된 두 단어 조합(bigram)도 함께 사용하였다.

전체 1,481,661건에 대해 TF-IDF 변환을 수행한 결과 상품별 최대 50,000개의 텍스트 특성이 생성되었으며, 대규모 고차원 데이터를 효율적으로 처리하기 위해 희소행렬(sparse matrix) 형태로 유지하였다.

5.3.4 Target 변환 및 최종 데이터셋 구성

가격 분포의 극단적인 우측 왜도(11.39)를 완화하기 위해 $\log_price = \log(1 + price)$ 변환을 적용하여 새로운 목표변수로 정의하였다.

원본 price는 예측 결과를 실제 가격 단위로 복원하기 위해 별도로 유지하였다.

전처리 데이터에서 완전히 동일한 행이 50건 확인되어 이를 제거한 결과 최종 1,481,611건이 확보되었으며, price는 3~2,009, log_price는 1.386~7.606 범위로 나타났다.

최종적으로 5.2.5절의 통계적 유의변수 297개(X_{final})와 TF-IDF 텍스트 특성(최대 50,000 차원)을 각각 별도로 저장하여, 이후 5.4절의 머신러닝 모델링에서 통계적으로 검증된 구조화 변수와 대규모 텍스트 특성을 조합해 활용할 수 있도록 구성하였다.

5.4 머신러닝 모델링 및 성능 비교

5.4.1 평가지표 및 실험 설계

가격 예측 성능은 RMSLE(Root Mean Squared Logarithmic Error)로 평가하였다.

RMSLE는 예측값과 실제값을 각각 $\log(1+x)$ 변환한 뒤 오차를 계산하므로, 고가 상품의 절대오차가 손실을 과도하게 지배하는 것을 방지하고 가격 분포의 우측 왜도에 상대적으로 강건하다는 장점이 있다.

데이터는 5.3절에서 구성한 정형 변수(297개)와 TF-IDF 텍스트 특성(최대 50,000차원)을 결합한 뒤 80/20 비율로 학습/평가 데이터를 분할하였고, 재현성을 위해 모든 실험에서 `random_state=42`를 고정하였다.

5.4.2 Ridge 회귀 베이스라인 및 하이퍼파라미터 튜닝

정형 변수 297개와 TF-IDF 5만 차원을 결합한 50,297차원 희소행렬을 입력으로 Ridge 회귀($\alpha=1.0$)를 적합한 결과 $\text{RMSLE}=0.4962$ 를 얻었다.

이는 5.2절의 통계적 회귀분석($R^2=0.2677$)과 달리 예측 성능 자체를 목표로 하며, 정규화(L2 penalty)를 통해 50,297차원의 고차원 희소 데이터에서도 안정적인 추정이 가능하다는 Ridge의 장점을 활용한 것이다.

이후 Optuna를 이용해 $\alpha(1e-3 \sim 100, \text{log-scale})$ 와 `solver(auto/sag/sparse_cg)`를 20회 시행으로 튜닝한 결과, $\alpha \approx 0.979 \cdot \text{solver}=\text{sag}$ 조합에서 $\text{RMSLE}=0.495943$ 으로 소폭 개선되었다.

베이스라인 대비 개선 폭이 크지 않은 것은 Ridge가 이미 안정적인 정규화 선형모형이며, $\alpha=1.0$ 이 기본값 자체로도 이 데이터에 준수하게 맞았음을 시사한다.

5.4.3 LightGBM(구조화 피처) 베이스라인

선형 모델의 한계(5.2.6절에서 확인한 Ramsey RESET 선형성 위반)를 고려하여 비선형 트리 기반 모델인 LightGBM을 적용하였다.

다만 메모리 제약을 고려하여 이 단계에서는 TF-IDF를 결합하지 않고 정형 변수(996개, 결측 처리 및 타입 정리 후)만을 사용하였다.

Optuna로 10회 시행 튜닝한 결과 $RMSLE=0.539283$ (num_leaves=189, max_depth=6, learning_rate $\approx$ 0.258)으로, 텍스트 정보를 포함하지 않았음에도 Ridge 베이스라인보다는 낮은 성능을 보였다.

이는 가격 예측에서 텍스트 정보(상품명·설명)가 갖는 설명력이 상당하며, 텍스트를 제외한 정형 변수만으로는 Ridge+TF-IDF 조합을 넘어서기 어렵다는 것을 시사한다.

5.4.4 어근추출(Lemmatization) 기반 텍스트 재처리와 앙상블 모델 비교

텍스트 정보의 기여도를 높이기 위해 WordNetLemmatizer로 어근을 추출한 뒤 TF-IDF를 재적합하였다(max_features=50,000, min_df=5, max_df=0.9, ngram_range=(1,2)).

정형 변수는 통계적으로 유의성이 검증된 297개(X_final)로 축소하여 결합함으로써 총 특성 차원을 유지하면서 노이즈가 될 수 있는 비유의 변수를 배제하였다.

동일한 방식으로 Ridge(Optuna 20회 튜닝), LightGBM(고정 파라미터), XGBoost(고정 파라미터)를 각각 학습한 결과, Ridge는 $RMSLE=0.483642$ 로 가장 우수하였으며, 이는 어근추출 이전 Ridge(0.495943)보다 개선된 수치로, 어근추출을 통한 어휘 정규화가 정규화 선형모형의 예측 성능을 실제로 향상시켰음을 보여준다.

LightGBM(0.503646)과 XGBoost(0.503814)는 Ridge보다는 낮았지만, 5.4.3절의 구조화 변수 전용 LightGBM(0.539283)보다는 개선되었다.

추가로 HistGradientBoosting 기반 GBM과 RandomForest를 동일한 데이터(정형 297개+ 어근추출 TF-IDF)로 학습하여 비교하였다.

GBM은 RMSLE=0.551998, RandomForest는 RMSLE=0.695365로, 두 모델 모두 Ridge·LightGBM·XGBoost보다 낮은 성능을 보였다.

특히 RandomForest의 성능 저하가 두드러졌는데, 이는 50,297차원의 초고차원 희소 데이터에서 각 트리가 무작위로 특성의 일부만 선택(feature bagging)하는 RandomForest의 구조적 특성상 유의미한 텍스트 특성을 충분히 활용하지 못했을 가능성을 시사한다.

GBM 역시 순차적으로 오차를 보정하는 부스팅 구조임에도 고정 파라미터만으로는 LightGBM·XGBoost 수준의 성능에 도달하지 못하였는데, 이는 트리 개수·학습률 등 하이퍼 파라미터 탐색이 이루어지지 않았기 때문일 가능성이 있다.

모델	입력 차원	어근추출 적용	RMSLE
Ridge (구조화+TF-IDF, alpha=1.0)	50,297	X	0.4962
Ridge (Optuna 튜닝)	50,297	X	0.495943
LightGBM (구조화 변수만, Optuna 튜닝)	996	X	0.539283
Ridge (어근추출 TF-IDF+X_final, Optuna 튜닝)	50,297	O	0.483642
LightGBM (어근추출, 고정 파라미터)	50,297	O	0.503646
XGBoost (어근추출, 고정 파라미터)	50,297	O	0.503814
GBM (HistGradientBoosting, 어근추출, 고정 파라미터)	50,297	O	0.551998
Random Forest (어근추출, 고정 파라미터)	50,297	O	0.695365

표 5-4. 머신러닝 모델별 예측 성능(RMSLE) 종합 비교

5.4.5 종합 성능 비교

본 프로젝트에서 시도한 8개 모델의 RMSLE를 비교하면(그림 5-17), 어근추출을 적용한 Ridge 회귀(RMSLE=0.483642)가 최종적으로 가장 우수한 예측 성능을 보였다.

성능 순위는 Ridge(Ch.9) < LightGBM(Ch.9) $\approx$ XGBoost(Ch.9) < GBM(Ch.10) < Random Forest(Ch.10) 순으로 나타났다.




그림 5-17. 머신러닝 모델별 RMSLE 종합 비교

이러한 결과는 다음과 같이 해석된다.

첫째, 정규화 선형모형(Ridge)이 50,000차원 이상의 고차원 희소 텍스트 데이터에서 가장 안정적으로 작동하였다.

둘째, 어근추출을 통한 어휘 정규화가 TF-IDF의 표현력을 개선하였다.

셋째, 통계적으로 유의성이 검증된 297개 정형 변수만을 결합함으로써 불필요한 노이즈 변수를 배제한 것이 함께 작용하였다.

반면 트리 기반 앙상블 모델(LightGBM, XGBoost, GBM, RandomForest)은 5.2.6절에서 확인한 OLS의 비선형성 위반을 완화할 이론적 잠재력이 있음에도, 본 데이터의 초고차원 희소 구조에서는 어느 것도 Ridge를 능가하지 못하였다.

특히 RandomForest와 GBM은 하이퍼파라미터 튜닝 없이 고정 파라미터로만 학습되었다는 점에서, 트리 기반 모델의 잠재력이 완전히 발휘되지 못했을 가능성도 함께 고려해야 한다.

5.5 결론 및 향후 개선 방안

본 장에서는 Mercari 상품 데이터 148만여 건을 대상으로 통계적 회귀분석과 머신러닝 모델링을 병행하여 상품 가격 결정 요인을 검증하고 예측 성능을 비교하였다.

다음 다섯 가지로 결론을 요약할 수 있다.

첫째, 통계적 회귀분석 결과 배송비 부담 주체(shipping), 상품 상태(item_condition_id), 카테고리(category_1/2/3)가 가격에 유의한 영향을 미치는 핵심 변수로 확인되었다.

특히 구매자가 배송비를 부담하는 상품일수록, 상품 상태가 나쁠수록 가격이 유의하게 낮아지는 경향이 확인되어(각각 $p < 0.001$), 애초에 설정한 통계적 질문에 실증적인 답을 제공하였다.

둘째, 다중공선성(VIF)과 유의성 검정을 반복 적용하여 882개의 초기 변수를 297개로 정제하면서도 모델 설명력(R^2)의 손실은 크지 않았다($0.2912 \rightarrow 0.2677$).

다만 Ramsey RESET 검정에서 선형성 가정이 위반되어($p < 0.001$), 선형 회귀만으로는 가격 결정 구조를 완전히 포착하지 못한다는 한계가 확인되었다.

셋째, 머신러닝 모델링에서는 텍스트 정보(상품명·상품 설명)를 포함한 Ridge 회귀가 텍스트를 제외한 LightGBM보다 우수한 성능을 보여, 텍스트 정보가 가격 예측에 실질적으로 기여함을 확인하였다.

나아가 어근추출(Lemmatization)을 통한 텍스트 정규화가 Ridge의 RMSLE를 0.495943에서 0.483642로 개선시켜, 단순한 모델 교체보다 텍스트 전처리 품질이 예측 성능에 미치는 영향이 클 수 있음을 보여주었다.

넷째, GBM·RandomForest를 포함한 트리 기반 앙상블 모델 4종(LightGBM, XGBoost, GBM, RandomForest)을 모두 비교한 결과, 이론적으로 비선형 관계와 변수 간 상호작용을 포착할 수 있는 트리 계열 모델임에도 어느 것도 Ridge 회귀를 능가하지 못하였다.

특히 RandomForest(RMSLE=0.695365)의 성능 저하가 두드러졌는데, 이는 초고차원 희소 데이터에서 트리 기반 모델이 저차원 조밀 데이터만큼 효율적으로 작동하지 않을 수 있음을

시사한다.

다섯째, GBM과 RandomForest는 하이퍼파라미터 튜닝 없이 고정 파라미터로만 학습되었다는 한계가 있다.

Ridge와 동일한 수준의 Optuna 기반 체계적 탐색이 이루어졌다면 두 모델의 성능이 개선되었을 가능성을 배제할 수 없으며, 이는 현재 순위가 트리 기반 모델의 최종적인 한계라기보다 실험 설계상의 한계일 수 있음을 의미한다.

향후 개선 방안으로는 다음을 제안한다.

(1) LightGBM·XGBoost·GBM·RandomForest 전체에 Ridge에 준하는 체계적인 하이퍼파라미터 탐색을 적용하여 현재의 성능 순위가 트리 모델의 실제 잠재력을 과소평가하고 있지 않은지 검증한다.

(2) TF-IDF 대신 word embedding이나 사전학습 언어모델 기반 텍스트 표현을 시도하여 텍스트 특성의 표현력을 추가로 개선한다.

(3) OLS의 선형성 위반을 고려하여 다항 특성이나 변수 간 교호작용항을 포함한 확장된 회귀모형을 검토한다.

(4) Ridge와 트리 기반 모델을 앙상블(스태킹)하여 두 계열 모델의 상호 보완 가능성을 탐색한다.

(5) RandomForest의 저조한 성능 원인을 특성 중요도 분석을 통해 구체적으로 규명한다.

6. 결론

6.1 4가지 핵심 과제별 주요 분석 결과 요약

본 보고서는 정형 데이터(산탄데르, 신용카드 사기 검출), 텍스트 데이터(Opinions 리뷰, Mercari 상품명·설명)를 아우르는 네 개의 독립적인 과제를 통해, 통계적 추론과 머신러닝 예측을 결합하는 분석 프레임워크를 일관되게 적용하였다.

각 과제의 핵심 결과를 요약하면 다음과 같다.

6.1.1 캐글 산탄데르: 고객 만족도 예측

약 4% 수준의 심각한 클래스 불균형을 가진 76,020건의 고객 데이터를 대상으로, 통계적 유의성 검정·상관관계 기반 중복 제거·LASSO·트리 기반 변수 중요도라는 네 가지 서로 다른 방법을 교차 검증하여 313개 후보 변수를 15개로 축소하였다.

이 중 13개(86.7%)가 네 방법 모두에서 공통으로 선택되어, 최종 변수 집합이 특정 알고리즘에 편향되지 않고 안정적으로 도출되었음을 확인하였다.

SMOTE로 클래스 불균형을 보정한 XGBoost는 Test 데이터에서 ROC-AUC 0.8172, PR-AUC 0.1496을 기록하였으며, Threshold를 0.70으로 최적화한 결과 Recall 43.26%로 불만족 고객 601명 중 260명을 사전에 식별할 수 있었다.

SHAP 분석 결과 var15(고객 연령대 관련 변수)가 가장 큰 영향력을 보였으며, 이는 2.1절 EDA에서 발견한 "연령대가 높을수록 불만족 비율이 상승한다"는 패턴과 정합적이었다.

6.1.2 캐글 신용카드 사기 검출

284,807건의 거래 중 사기 거래가 약 0.17%에 불과한 극단적 불균형 데이터를 대상으로, Mann-Whitney U 검정과 Cohen's d(FDR 보정 적용)를 통해 V17·V14·V12·V10·V16 등이 정상·사기 거래를 매우 큰 폭(효과크기 2.7~8.3)으로 구분함을 확인하였다.

다변량 로지스틱 회귀·오즈비 분석에서는 V4(OR=2.22)가 가장 강력한 위험 요인, V10(OR=0.41)이 가장 강력한 보호 요인으로 나타났으며, 이는 단변량 분석과 상당 부분 일치하되 V17처럼 다변량에서는 상대적으로 약화되는 변수도 있어 두 접근이 상호 보완적임을 보였다.

5개 모델×3가지 불균형 처리 기법(총 15개 조합) 비교와 Hyperopt 기반 정밀 튜닝을 거쳐, 기본 임계값 기준으로는 XGBoost가 미탐지·오탐지 균형 면에서 가장 안정적이었고, 임계값을 0.9919로 최적화하면 오탐지를 2건까지 억제하면서 사기 79.6%를 탐지할 수 있음을 확인하였다.

다만 ROC-AUC가 가장 높았던 모델(Gradient Boosting, 0.9807)의 Precision이 10.85%에 불과했던 사례는, 불균형 데이터에서 단일 지표만으로 모델을 판단해서는 안 된다는 점을 명확히 보여주었다.

6.1.3 Opinions 리뷰 텍스트 군집분석

13개 제품·서비스에 대한 리뷰 문장 7,086개를 TF-IDF(3,000차원)·TruncatedSVD(100차원)·KMeans(K=12, 엘보우 방법)로 군집화한 결과, 자동차·전자제품·호텔이라는 3개 대주제, 12개 세부 군집으로 구조화되었다.

Ridge 및 OLS 회귀(HC3 강건표준오차) 분석을 통해 호텔 입지(cluster_8, coef=+0.31)·직원 응대(cluster_11, coef=+0.31)·배터리 지속시간(cluster_3, coef=+0.23)이 감성을 유의하게 높이고, 자동차 좌석·변속기(cluster_1, coef=-0.30)가 감성을 유의하게 낮추는 핵심 주제로 확인되었다(12개 중 6개 군집이 $p < 0.001$ 수준에서 유의, Bonferroni 보정 후에도 건

고).

위계적 회귀 F검정($\Delta R^2=0.024$, $p<0.001$)을 통해 군집이라는 요인 자체가 감성에 대한 설명력을 유의하게 추가함을 확인하였으나, 실루엣 점수(0.06)로 대표되는 기하학적 분리도는 낮게 나타나 통계적 설명력과 군집의 기하학적 응집도가 별개의 지표임을 확인하였다.

아울러 cluster_0(전체 문장의 37.1%)과 같은 대규모 혼합형 잔여 군집의 존재는 비지도 텍스트 군집화의 구조적 한계로 해석하였다.

6.1.4 Mercari 상품 가격 예측

148만여 건의 상품 데이터를 대상으로, 극단적인 우측 왜도(11.39)를 보인 가격을 로그 변환(왜도 0.70)한 뒤 다중회귀분석을 수행하였다.

882개 설명변수로 출발하여 유의성 검정과 VIF 다중공선성 진단을 반복 적용해 297개 변수로 정제하였으며($R^2=0.2912 \rightarrow 0.2677$), 이 과정에서 대량의 개별 가설검정에 따른 다중검정 문제를 명시적으로 검토하여 핵심 결론의 견고성을 확인하였다.

회귀분석 가정 검토에서는 독립성(Durbin-Watson 1.998)·등분산성·정규성은 만족하였으나 Ramsey RESET 검정($p<0.001$)에서 선형성이 위반되어, 비선형 모델 도입의 통계적 근거를 확보하였다.

그러나 실제 머신러닝 모델 비교에서는 어근추출(Lemmatization)을 적용한 Ridge 회귀(RMSLE=0.483642)가 LightGBM(0.503646)·XGBoost(0.503814)·GBM(0.551998)·RandomForest(0.695365) 등 모든 비선형 트리 기반 모델을 능가하는 예상 밖의 결과를 얻었다.

이는 정규화 선형모형이 50,000차원 이상의 초고차원 희소 텍스트 데이터에서는 트리 기반 모델보다 오히려 안정적으로 작동할 수 있음을 시사하는 결과였다.

과제	데이터 규모	최종 채택 모델	핵심 성능 지표
산탄데르 (고객 만족도)	76,020건, 15개 변수	XGBoost (SMOTE)	ROC-AUC 0.8172
신용카드 사기 검출	284,807건, 30개 변수	XGBoost (Threshold 최적화)	PR-AUC 0.8845, Precision 0.975
Opinions 리뷰 군집분석	7,086개 문장, 12개 군집	KMeans + Ridge/OLS	위계적 F검정 $p < 0.001$
Mercari 가격 예측	1,481,611건, 50,297차원	Ridge (어근추출+Optuna)	RMSLE 0.483642

표 6-1. 4가지 핵심 과제 분석 결과 종합 비교

6.2 종합 시사점 및 향후 제언

6.2.1 통계적 분석과 머신러닝의 상호보완적 활용

네 과제 모두에서 공통적으로 확인된 첫 번째 시사점은, 통계적 추론과 머신러닝 예측이 서로 다른 질문에 답하는 상호보완적 도구라는 점이다.

산탄데르에서는 통계적 유의성 검정·LASSO·트리 기반 중요도라는 서로 다른 성격의 방법이 86.7%의 변수 집합에서 일치함으로써 변수 선택의 신뢰도를 높였고, 신용카드 사기 검출에서는 단변량 효과크기(Cohen's d)와 다변량 오즈비, SHAP 값이 서로 다른 각도에서 핵심 변수를 조명하며 상호 검증하였다.

Opinions 군집분석에서는 Ridge의 예측 계수를 OLS의 유의성 검정으로 재검증하였고, Mercari에서는 통계적 회귀분석이 밝혀낸 선형성 가정 위반이 비선형 머신러닝 모델을 도입해야 하는 근거로 직접 연결되었다.

즉 통계적 방법은 "왜, 어떤 변수가, 어떤 방향과 확신도로" 결과에 기여하는지를 설명하고, 머신러닝은 "얼마나 정확하게" 예측할 수 있는지를 보여주며, 두 접근을 병행할 때 해석 가능성과 예측 성능을 동시에 확보할 수 있었다.

6.2.2 데이터 특성에 따른 최적 모델링 전략의 차이

네 과제의 결과를 교차 비교하면, "가장 좋은 모델"은 데이터의 구조에 따라 달라진다는 점이 뚜렷하게 드러난다.

정형 변수 중심이고 표본 대비 변수 수가 상대적으로 적은 산탄데르·신용카드 데이터에서는 XGBoost·Random Forest 등 트리 기반 앙상블이 로지스틱 회귀보다 우수한 성능을 보

였다.

반면 50,000차원을 넘는 초고차원 희소 텍스트 데이터를 다룬 Mercari에서는 오히려 정규화 선형모형(Ridge)이 모든 트리 기반 모델을 능가하였다.

이는 트리 기반 모델이 각 분기(split)마다 유한한 수의 특성만 활용하는 구조적 특성상, 텍스트처럼 극도로 희소하고 고차원적인 데이터에서는 유의미한 신호를 충분히 포착하지 못할 수 있음을 보여준다.

따라서 "비선형 모델이 항상 선형 모델보다 우수하다"는 일반화는 성립하지 않으며, 데이터의 차원·희소성·표본 크기를 함께 고려하여 모델 계열을 선택해야 한다는 실무적 시사점을 얻었다.

6.2.3 공통적으로 적용된 통계적 엄밀성의 원칙

본 보고서 전반에 걸쳐 다음과 같은 통계적 엄밀성의 원칙을 일관되게 적용하고자 하였다.

첫째, 대규모 표본에서는 통계적 유의성(p-value)만으로 판단하지 않고 효과크기(Cohen's d, 오즈비, 회귀계수)를 함께 검토하여 실질적 유의성을 확인하였다(3.2.2절).

둘째, 다수의 변수를 동시에 검정할 때는 Benjamini-Hochberg FDR 보정 또는 Bonferroni 보정을 통해 다중검정에 따른 1종 오류 팽창 문제를 명시적으로 통제하였다(2.2.2절, 3.2.2절, 4.4.1절, 5.2.5절).

셋째, 회귀모형 적용 전후로 정규성·독립성·등분산성·선형성·다중공선성(VIF) 등 표준적인 가정을 순차적으로 검토하고, 가정이 위반된 경우(예: Mercari의 선형성 위반) 이를 은폐하지 않고 모델의 한계이자 대안적 접근의 근거로 명시하였다(3.2.1절, 4.4절, 5.2.6절).

넷째, 단일 지표에 의존한 모델 평가를 지양하고 ROC-AUC·PR-AUC·Precision·Recall·F1-score를 함께 검토하여, 불균형 데이터에서 하나의 지표만으로는 왜곡된 결론에 도달

할 수 있음을 반복적으로 확인하였다(3.8.3절).

6.2.4 연구의 한계와 향후 과제

본 분석에는 다음과 같은 공통적인 한계가 존재하며, 이는 후속 연구에서 보완이 필요하다.

첫째, 모든 분석은 특정 시점에 수집된 관측 데이터(observational data)를 기반으로 하므로, 통계적으로 유의한 관계가 확인되었더라도 이를 인과관계로 해석하는 데에는 주의가 필요하다.

예를 들어 Mercari에서 배송비 부담 주체가 가격과 유의한 관계를 보였다는 결과는 상관관계이지, 배송비 정책을 바꾸면 가격이 그만큼 변한다는 인과적 개입 효과를 의미하지는 않는다.

둘째, 하이퍼파라미터 탐색의 깊이가 모델마다 균일하지 않았다.

특히 Mercari의 GBM·RandomForest는 Ridge에 적용한 것과 같은 체계적인 Optuna 탐색 없이 고정 파라미터로만 학습되어, 현재의 성능 순위가 각 모델의 최종적인 잠재력을 완전히 반영하지 못했을 가능성이 있다.

셋째, 신용카드 사기 검출과 Mercari 사례처럼 데이터 규모가 매우 큰 경우 계산 자원의 제약으로 일부 단계(통계적 추론, 하이퍼파라미터 탐색)에서 무작위 표본이나 축소된 탐색 범위를 사용하였으며, 이는 전체 모집단을 정확히 대표하지 못할 가능성을 내포한다.

넷째, Opinions 군집분석의 cluster_0과 같은 대규모 혼합형 잔여 군집, Mercari의 선형성 가정 위반 등 일부 결과는 완전히 해소되지 못한 구조적 한계로 남아있다.

이러한 한계를 고려하여 향후에는 (1) 가능한 경우 준실험적 설계나 도구변수 등을 활용한 인과추론 기법을 도입하고, (2) 모든 모델 계열에 동일한 수준의 체계적 하이퍼파라미터 탐색을 적용하여 모델 간 비교의 공정성을 높이며, (3) 시계열적으로 데이터를 확장하여 특정 시점에 국한되지 않는 일반화 가능성을 검증하고, (4) 통계적 추론 단계와 머신러닝 모델링

단계에서 사용하는 표본을 일치시켜 두 결과 간의 정합성을 더 엄밀하게 검증하는 것을 제안한다.

종합적으로, 본 보고서는 정형·비정형 데이터, 이진분류·회귀·비지도학습이라는 서로 다른 문제 유형에 걸쳐 통계적 추론과 머신러닝을 결합하는 일관된 분석 프레임워크를 적용함으로써, 데이터의 특성에 따라 최적의 방법론이 달라진다는 것과, 두 접근을 병행할 때 예측 성능과 해석 가능성을 동시에 확보할 수 있다는 것을 실증적으로 보여주었다.